

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



TAREA ACADÉMICA IEE352 - PROCESAMIENTO DIGITAL DE SEÑALES

“Diseño de Filtros Digitales, Algoritmos LMS y Ecualización de Canal”

Alumno:

20202132 - LIN CHAN, KENT JIANBIN

Docente:

MILLA BRAVO, MARCO ANTONIO

Lima, junio de 2026

Tabla de contenido

1.	Diseño de filtros digitales	6
1.1.	Diseño de Filtro Digital con Ventana Kaiser.....	7
1.1.1.	Método de Ventana Kaiser	7
1.1.2.	Cálculo del parámetro β	9
1.1.3.	Cálculo de la longitud del filtro M	9
1.1.4.	Respuesta impulsiva del filtro ideal	10
1.1.5.	Coeficientes del filtro FIR	10
1.1.6.	Resultados del Diseño	10
1.1.7.	Clasificación del filtro	11
1.1.8.	Análisis de la Respuesta en Frecuencia	11
1.1.9.	Análisis espectral del filtro	13
1.1.10.	Análisis de fase y retardo de grupo	13
1.1.11.	Verificación de Especificaciones.....	14
1.1.12.	Conclusiones.....	14
1.2.	Diseño de Filtro FIR Compensador para CICs.....	14
1.2.1.	¿Qué es un filtro CIC y por qué se usa?	14
1.2.2.	El problema del droop en la banda de paso	15
1.2.3.	Filtro compensador	15
1.2.4.	¿Por qué FIR y no IIR en el compensador?.....	16
1.2.5.	Flujo del sistema.....	16
1.2.6.	Parámetros del FIR compensador.....	16
1.2.7.	Diseño mediante Parks-McClellan	17
1.2.8.	Parámetros del FIR compensador.....	18
1.2.9.	Coeficientes del FIR	18
1.2.10.	Clasificación del filtro	18
1.2.11.	Análisis de la Respuesta en Frecuencia.....	19
1.2.12.	Análisis de fase y retardo de grupo	22
1.2.13.	Verificación de Especificaciones	22
1.2.13.	Conclusiones.....	23
1.3.	Comparación de Filtros y Selección.....	24
1.3.1.	Tabla Comparativa: Parte 1 vs Parte 2	24
1.3.2.	Metodología de Comparación	25

1.3.3.	Comparación de Magnitud	25
1.3.4.	Comparación de Fase.....	26
1.3.5.	Filtro Más Adecuado para la Aplicación.....	27
2.	Comparación de Algoritmos LMS	28
2.1.	Predictor lineal y Filtro Wiener	28
2.2.	Derivación del LMS por gradiente descendente.....	29
2.2.1.	Gradiente del MSE	29
2.2.2.	Gradiente descendente	29
2.2.3.	Aproximación estocástica.....	29
2.2.4.	Algoritmo LMS	29
2.2.5.	Convergencia	30
2.3.	Algoritmos LMS comparados	30
2.3.1.	LMS.....	30
2.3.2.	LMS normalizado (NLMS)	30
2.3.3.	LMS-Newton.....	31
2.4.	Parámetros del sistema	32
2.5.	Procedimiento	32
2.5.1.	Generación de la Señal AR(2).....	32
2.5.2.	Implementación de los Algoritmos.....	33
2.5.2.1.	LMS:.....	33
2.5.2.2.	LMS normalizado:.....	34
2.5.2.3.	LMS-Newton:.....	34
2.5.2.4.	Verificación con un μ arbitrario	35
2.5.3.	Comparación con 100 Realizaciones.....	35
2.5.3.1.	Misma Varianza, Comparar Velocidad	36
2.5.3.2.	Misma Velocidad, Comparar Varianza	37
2.6.	Conclusiones.....	38
3.	Ecualización de Canal	40
3.1.	Sistema de comunicación con ISI.....	40
3.1.1.	Criterio de Nyquist para ISI cero.....	40
3.2.	Filtro de Wiener y ecualización adaptativa	42
3.3.	Modulación QPSK.....	43
3.3.1.	Probabilidad de error teórica de QPSK en AWGN	44

3.4.	Algoritmo LMS (Widrow-Hoff).....	44
3.5.	Modo Decision-Directed	45
3.6.	Ecualizador DFE (Decision Feedback Equalizer)	45
3.7.	Modelo del Sistema y Carga de Datos	45
3.7.1.	Datos cargados.....	46
3.7.2.	Verificación de la codificación/decodificación	46
3.8.	Constelación de la señal recibida.....	46
3.9.	Estimación de los Coeficientes del Canal.....	46
3.10.	Evolución temporal de los coeficientes del canal.....	47
3.11.	Zero-Forcing con canal estimado	48
3.12.	Ecualizador LMS Lineal.....	49
3.12.1.	Selección de parámetros	49
3.12.2.	Resultados del entrenamiento.....	50
3.13.	Análisis de Convergencia	50
3.14.	Constelación Post-Ecualización	51
3.15.	Recuperación del Mensaje.....	52
3.16.	Ecualizador DFE	53
3.17.	Comparación LMS Lineal vs DFE	53
3.18.	Conclusiones.....	54
	Referencias bibliográficas	56

Tabla de ilustraciones

Figura 1 - Diagrama de bloques de sistema de recepción de señales de radar.....	6
Figura 2 - Parámetros que caracterizan el diseño de un filtro digital.....	6
Figura 3 - Propiedades de las cinco ventanas más usadas en diseño FIR	8
Figura 4 - Ecuación de la ventana de Kaiser	9
Figura 5 - Función de Bessel modificada de primera especie de orden cero	9
Figura 6 - Fórmula empírica de Kaiser para el parámetro de forma β	9
Figura 7 - Coeficientes del filtro FIR diseñados con ventana Kaiser.....	12
Figura 8 - Respuesta en frecuencia del Kaiser	13
Figura 9 - Flujo del sistema con CIC.....	16
Figura 10 - Coeficientes del FIR compensador.....	19
Figura 11 - Respuesta en frecuencia del FIR compensador	20
Figura 12 - Filtro resultante CIC + FIR.....	21
Figura 13 - Comparación de magnitud Kaiser vs CIC+FIR.....	25
Figura 14 - Comparación de fase Kaiser vs CIC+FIR	26
Figura 15 - Ecuación matricial de Wiener-Hopf para el predictor lineal	28
Figura 16 - Ecuación de actualización del LMS normalizado (NLMS).....	30
Figura 17 - Ecuación de actualización del LMS-Newton	31
Figura 18 - Diagrama del predictor lineal	31
Figura 19 - Convergencia con μ arbitrario	35
Figura 20 - Coeficientes promedio vs n con varianza igualada.....	36
Figura 21 - Coeficientes promedio vs n con velocidad igualada.....	37
Figura 22 - Diagrama del ojo.....	41
Figura 23 - Coseno elevado.....	41
Figura 24 - Constelación QPSK	43
Figura 25 - Modulación QPSK.....	43
Figura 26 - Constelación de $y[n]$	46
Figura 27 - Coeficientes del canal estimados por LMS en el entrenamiento	48
Figura 28 - Convergencia del ecualizador LMS lineal.....	51
Figura 29 - Constelación antes y después de ecualizar	52
Figura 30 - Comparación LMS Lineal vs DFE	54

1. Diseño de filtros digitales

En los sistemas de recepción de señales de radar basados en dispositivos SDR (Software Defined Radio), la señal digitalizada pasa por un demodulador para llevar la señal a banda base, seguido de un filtro pasabajos y finalmente un decimador para reducir la tasa de muestreo. El filtro pasabajos es necesario para evitar el aliasing durante la decimación, respetando el criterio de Nyquist.




Figura 1 - Diagrama de bloques de sistema de recepción de señales de radar.




Figura 2 - Parámetros que caracterizan el diseño de un filtro digital.

Nota. Tomado de *Applied Digital Signal Processing: Theory and Practice* (p. 539), por D. G. Manolakis y V. K. Ingle, 2011, Cambridge University Press.

Para realizar el diseño del filtro consideremos las siguientes especificaciones que se determinaron en función de los requisitos del sistema de radar SDR:

Parámetro	Valor	Descripción
F_s	100 MHz	Frecuencia de muestreo
F'_s	1 MHz	Frecuencia de muestreo post-decimación
F_c	500 kHz	Frecuencia de corte
A	80 dB	Atenuación mínima en banda de rechazo
Δf	100 kHz	Ancho de transición máximo ($10\% \times F_s'$)

1.1. Diseño de Filtro Digital con Ventana Kaiser

1.1.1. Método de Ventana Kaiser

Para este diseño se utilizó el método de enventanado con ventana Kaiser, el cual permite controlar directamente la atenuación en la banda de rechazo mediante el parámetro β , mientras que la longitud del filtro L determina el ancho de la banda de transición. Este método, descrito en el Capítulo 10 de Manolakis & Ingle (2011), es ampliamente utilizado en aplicaciones de comunicaciones por su simplicidad y efectividad.

La siguiente tabla compara las características de distintas ventanas para una longitud típica $N=M+1$:

Como se observa, la ventana Kaiser con $\beta=7.86$ logra 80 dB de atenuación con un rizado inferior al de Blackman pero con menor ancho de transición, lo cual la hace óptima para especificaciones estrictas como las de este problema.

Ventana	Atenuación típica	Ancho de transición	Rizado
Rectangular	21 dB	0.02π	Alto
Hann	44 dB	0.032π	0.056 dB
Hamming	53 dB	0.036π	0.019 dB
Blackman	75 dB	0.044π	0.0017 dB
Kaiser ($\beta=7.86$)	80 dB	0.036π	0.001 dB

Window name	Side lobe level (dB)	Approx. $\Delta\omega$	Exact $\Delta\omega$	$\delta_p \approx \delta_s$	A_p (dB)	A_s (dB)
Rectangular	-13	$4\pi/L$	$1.8\pi/L$	0.09	0.75	21
Bartlett	-25	$8\pi/L$	$6.1\pi/L$	0.05	0.45	26
Hann	-31	$8\pi/L$	$6.2\pi/L$	0.0063	0.055	44
Hamming	-41	$8\pi/L$	$6.6\pi/L$	0.0022	0.019	53
Blackman	-57	$12\pi/L$	$11\pi/L$	0.0002	0.0017	74

Figura 3 - Propiedades de las cinco ventanas más usadas en diseño FIR

Nota. Tomado de *Applied Digital Signal Processing: Theory and Practice* (p. 563), por D. G. Manolakis y V. K. Ingle, 2011, Cambridge University Press.

Para aplicaciones de radar, los filtros FIR son preferidos sobre los IIR por las siguientes razones:

1. Fase lineal exacta: Los filtros FIR de tipo I (simetría par, longitud impar) poseen respuesta de fase estrictamente lineal: $\phi(\omega) = -\omega\alpha$, lo que implica un retardo de grupo constante para todas las frecuencias. En contraste, los filtros IIR (Butterworth, Chebyshev, Elíptico) tienen fase no lineal, distorsionando la forma de los pulsos reflejados del radar.
2. Estabilidad garantizada: Los filtros FIR son siempre estables por definición, mientras que los IIR pueden volverse inestables debido a errores de cuantización en implementación de punto fijo.
3. Predictibilidad: La respuesta en frecuencia de un FIR depende únicamente de sus coeficientes, sin dependencia de polos que puedan causar comportamientos inesperados.

El diseño de filtros FIR mediante enventanado consiste en multiplicar la respuesta impulsiva del filtro ideal por una ventana finita que limita la extensión temporal del filtro. La ventana Kaiser se define como:

$$w[n] = \begin{cases} \frac{I_0 \left[\beta \sqrt{1 - [(n - \alpha)/\alpha]^2} \right]}{I_0(\beta)}, & 0 \leq n \leq M \\ 0, & \text{otherwise} \end{cases}$$

Figura 4 - Ecuación de la ventana de Kaiser

Nota. Tomado de *Applied Digital Signal Processing: Theory and Practice* (p. 566), por D. G. Manolakis y V. K. Ingle, 2011, Cambridge University Press.

Donde $I_0(\cdot)$ es la función de Bessel modificada de primera especie y orden cero.

$$I_0(x) = 1 + \sum_{m=1}^{\infty} \left[\frac{(x/2)^m}{m!} \right].$$

Figura 5 - Función de Bessel modificada de primera especie de orden cero

Nota. Tomado de *Applied Digital Signal Processing: Theory and Practice* (p. 567), por D. G. Manolakis y V. K. Ingle, 2011, Cambridge University Press.

1.1.2. Cálculo del parámetro β

El parámetro β controla la forma de la ventana y, por ende, la relación entre la atenuación en la banda de rechazo y el ancho de la banda de transición:

$$\beta = \begin{cases} 0, & A < 21 \\ 0.5842(A - 21)^{0.4} + 0.07886(A - 21), & 21 \leq A \leq 50 \\ 0.1102(A - 8.7), & A > 50 \end{cases}$$

Figura 6 - Fórmula empírica de Kaiser para el parámetro de forma β

Nota. Tomado de *Applied Digital Signal Processing: Theory and Practice* (p. 567), por D. G. Manolakis y V. K. Ingle, 2011, Cambridge University Press.

Para $A_{stop}=80$ dB (mayor a 50 dB):

$$\beta = 0.1102(80 - 8.7) = 7.8573$$

1.1.3. Cálculo de la longitud del filtro M

La longitud del filtro se calcula a partir del ancho de transición normalizado:

$$\Delta\omega = 2\pi \frac{\Delta f}{F_s}$$

$$M \approx \frac{A_{stop} - 8}{2.285\Delta\omega}$$

El ancho de transición normalizado es:

$$\Delta\omega = 2\pi \times \frac{100 \text{ kHz}}{100 \text{ MHz}} = 0.006283 \text{ rad/muestra}$$

Por lo tanto:

$$M = \frac{80 - 8}{2.285 \times 0.006283} = 5016$$

$$L = M + 1 = 5017(\text{coeficientes})$$

$$\alpha = \frac{M}{2} = 2508$$

1.1.4. Respuesta impulsiva del filtro ideal

La respuesta impulsiva del filtro pasabajos ideal con frecuencia de corte ω_c es:

$$h_d[n] = \frac{\omega_c}{\pi} \text{sinc}\left(\frac{\omega_c(n - \alpha)}{\pi}\right)$$

La frecuencia de corte normalizada respecto a Nyquist es:

$$f_{c,norm} = \frac{F_c}{F_s/2} = \frac{500 \text{ kHz}}{50 \text{ MHz}} = 0.01$$

$$\omega_c = \pi \times f_{c,norm} = 0.0314 \text{ rad/muestra}$$

1.1.5. Coeficientes del filtro FIR

Los coeficientes finales del filtro se obtienen multiplicando la respuesta impulsiva ideal por la ventana Kaiser:

$$h[n] = h_d[n] \cdot w[n], \quad 0 \leq n \leq M$$

1.1.6. Resultados del Diseño

Los parámetros calculados para el filtro diseñado son:

Parámetro	Valor
Parámetro β de Kaiser	7.8573
Orden M	5016
Longitud total L	5017
Centro α	2508
Frecuencia de corte ω_c	0.0314 rad/muestra

Los primeros 10 coeficientes del filtro son:

```
[-8.43564058e-08 -7.49381121e-08 -6.51859388e-08 -5.51052419e-08  
-4.47019285e-08 -3.39824583e-08 -2.29538441e-08 -1.16236519e-08  
-1.83951246e-22 1.19084427e-08]
```

1.1.7. Clasificación del filtro

Se comprobó la simetría y el residuo de los N puntos con 2 para la detección del tipo de filtro. Para ello se usó el siguiente código:

```
# Verificar simetría  
is_symmetric = np.allclose(h, h[::-1])  
is_antisymmetric = np.allclose(h, -h[::-1])  
  
print(f"\n¿Simetría par? {is_symmetric}")  
print(f"¿Simetría impar? {is_antisymmetric}")  
  
# Determinar tipo  
N = len(h)  
if is_symmetric and N % 2 == 1:  
    tipo = "Tipo I (N impar, simetría par)"  
elif is_symmetric and N % 2 == 0:  
    tipo = "Tipo II (N par, simetría par)"  
elif is_antisymmetric and N % 2 == 1:  
    tipo = "Tipo III (N impar, simetría impar)"  
elif is_antisymmetric and N % 2 == 0:  
    tipo = "Tipo IV (N par, simetría impar)"  
else:  
    tipo = "No es FIR de fase lineal estándar"
```

donde h representa los coeficientes del filtro FIR. La respuesta nos dio que es Tipo I, debido a que el número de puntos N es impar y tiene simetría par, lo cual garantiza fase lineal y es adecuado para aplicaciones donde la distorsión de fase debe ser mínima. Esta propiedad de los filtros FIR de fase lineal se describe de manera clásica en Oppenheim y Schaffer (2010).

1.1.8. Análisis de la Respuesta en Frecuencia

La respuesta en frecuencia se calculó utilizando FFT con zero-padding ($N_{fft} = 2^{17}$) para obtener alta resolución:

$$Resolución = \frac{F_s}{N_{fft}} = \frac{10^8}{2^{17}} = 762.94 \text{ Hz}$$

Se observa que los coeficientes presentan simetría par y forma de campana, lo cual es consistente con la ventana Kaiser modulando una respuesta sinc ideal, como se muestra en la siguiente figura.




Figura 7 - Coeficientes del filtro FIR diseñados con ventana Kaiser

La respuesta en magnitud lineal muestra el comportamiento pasabajos ideal con ganancia unitaria en frecuencias cercanas a cero y atenuación progresiva hacia la frecuencia de corte.

La respuesta en magnitud en dB permite apreciar claramente las bandas de paso, transición y rechazo, con líneas de referencia a -3 dB y -80 dB indicando el cumplimiento de especificaciones, como se muestra en la siguiente figura.

La respuesta de fase exhibe linealidad en la banda de paso, confirmando un retardo de grupo constante. A continuación, se muestra el siguiente gráfico.




Figura 8 - Respuesta en frecuencia del Kaiser

1.1.9. Análisis espectral del filtro

La atenuación cambia de -3 dB a -80 dB en aproximadamente 104 kHz, lo que equivale a una pendiente promedio de 0.74 dB/kHz.

La relación entre β y la atenuación, se evidencia que con $\beta=7.8573$, la ventana Kaiser produce lóbulos laterales aproximadamente 80 dB por debajo del lóbulo principal. Cada incremento de $\beta \approx 1$ reduce los lóbulos laterales de aproximadamente 10 dB, lo que justifica la elección de este parámetro.

1.1.10. Análisis de fase y retardo de grupo

El filtro Tipo I tiene respuesta de fase:

$$\phi(\omega) = -\omega\alpha = -\omega \times 2508$$

Esto implica un retardo de grupo constante de exactamente 2508 muestras para todas las frecuencias en la banda de paso. En aplicaciones de radar, esta característica es esencial porque los ecos reflejados mantienen su forma temporal original y la información de tiempo de llegada no se distorsiona.

1.1.11. Verificación de Especificaciones

La siguiente tabla resume los parámetros del filtro diseñado y su cumplimiento con las especificaciones:

Parámetro	Especificación	Obtenido
Atenuación en banda de rechazo	≥ 80 dB	80.28 dB
Ancho de transición	≤ 100 kHz	103.89 kHz
Rizado en banda de paso	-	0.00158 dB

1.1.12. Conclusiones

Del diseño del filtro FIR con ventana Kaiser se concluye que:

1. El método de enventanado con ventana Kaiser permite diseñar filtros alcanzando 80 dB de atenuación en la banda de rechazo con una longitud razonable de 5017 coeficientes.
2. La elección de la ventana Kaiser sobre otras alternativas se justifica por su capacidad de controlar directamente la atenuación mediante β , simplificando el proceso de diseño iterativo.
3. El filtro diseñado es de Tipo I (simetría par, longitud impar), lo cual garantiza fase lineal y un retardo de grupo constante en la banda de paso, características esenciales para sistemas de radar donde la distorsión temporal degrada la detección.
4. El ancho de transición del filtro (103.89 kHz) es ligeramente mayor al especificado (100 kHz), sin embargo, este resultado es aceptable considerando que el diseño optimiza la longitud del filtro.
5. El filtro cumple con el objetivo de proporcionar selectividad espectral adecuada para el sistema de radar SDR, permitiendo una posterior decimación sin aliasing significativo.

1.2. Diseño de Filtro FIR Compensador para CICs

1.2.1. ¿Qué es un filtro CIC y por qué se usa?

Los filtros CIC (Cascaded Integrator-Comb) son una clase de filtros digitales de respuesta finita al impulso (FIR) que pueden implementarse sin necesidad de multiplicadores, usando únicamente sumadores, restadores y registros de desplazamiento. Esto los hace extremadamente eficientes para aplicaciones que requieren altas tasas de decimación o interpolación, como ocurre en los sistemas de radar SDR.

La función de transferencia de un CIC de orden N y factor de decimación M es:

$$H_{CIC}(z) = \left(\frac{1 - z^{-M}}{1 - z^{-1}} \right)^N$$

Para este problema se tienen dos CICs en cascada:

$$H_{CIC2}(z) = \left(\frac{1 - z^{-2}}{1 - z^{-1}} \right)^2, \quad M_2 = 2, \quad N_2 = 2$$

$$H_{CIC5}(z) = \left(\frac{1 - z^{-5}}{1 - z^{-1}} \right)^5, \quad M_5 = 5, \quad N_5 = 5$$

La respuesta en frecuencia analítica de un CIC es:

$$H_{CIC}(e^{j\omega}) = \left(\frac{\sin(\omega M/2)}{\sin(\omega/2)} \right)^N \cdot e^{-j\omega(M-1)N/2}$$

Donde $\omega = 2\pi f/F_s$ es la frecuencia normalizada respecto a la tasa de muestreo de cada etapa.

La decimación total del sistema es $M = M_2 \cdot M_5 \cdot M_{FIR} = 2 \cdot 5 \cdot 10 = 100$, lo que reduce la tasa de muestreo de 100 MHz a 1 MHz.

1.2.2. El problema del droop en la banda de paso

La principal desventaja de los filtros CIC es que su respuesta en magnitud no es constante en la banda de paso, sino que presenta una caída gradual (droop) a medida que la frecuencia se acerca al borde de la banda. Para un CIC de orden N y factor de decimación M:

$$|H_{CIC}(f)| = \left| \frac{\sin(\pi f M/F_s)}{\sin(\pi f/F_s)} \right|^N$$

En la cascada $CIC_2 * CIC_5$ de este problema, el droop es pequeño, pero suficiente para requerir compensación, especialmente en sistemas de radar donde se busca una respuesta en frecuencia plana en la banda de paso.

1.2.3. Filtro compensador

Para corregir el droop del CIC, se coloca un filtro FIR compensador después de la cascada de CICs. La función de transferencia objetivo del compensador es el inverso de la respuesta del CIC en la banda de paso. De esta forma, la respuesta en cascada es $H_{total}(f) = H_{CIC}(f) \cdot H_{comp}(f)$ es aproximadamente constante a 1 en la banda de paso.

1.2.4. ¿Por qué FIR y no IIR en el compensador?

Al igual que en la Parte 1, se prefiere un filtro FIR sobre un IIR para el compensador por las siguientes razones:

1. Fase lineal exacta: Los filtros FIR de Tipo I (simetría par, longitud impar) tienen respuesta de fase estrictamente lineal: $\phi(\omega) = -\omega$, lo que implica retardo de grupo constante. En sistemas de radar, esto es crítico para preservar la forma de los pulsos reflejados.
2. Estabilidad garantizada: Los filtros FIR son siempre estables.
3. Costo computacional aceptable: Aunque el FIR es más largo que un IIR, opera a una tasa reducida (10 MHz en lugar de 100 MHz), gracias a la decimación previa de los CICs.

1.2.5. Flujo del sistema




Figura 9 - Flujo del sistema con CIC

El flujo es:

1. La señal entra al CIC2 a 100 MHz, que la decimación por 2 produce 50 MHz.
2. La salida del CIC2 entra al CIC5 a 50 MHz, que decimación por 5 produce 10 MHz.
3. La salida del CIC5 entra al FIR compensador a 10 MHz, que decimación por 10 produce 1 MHz.

1.2.6. Parámetros del FIR compensador

El FIR opera a $F_{s,FIR} = 10$ MHz, una tasa 10 veces menor que la entrada original. Esto reduce significativamente el costo computacional.

Para el diseño del FIR compensador se utiliza el algoritmo de Parks-McClellan que produce un filtro FIR equiripple de fase lineal. A diferencia del método de ventana Kaiser, PM permite controlar directamente la magnitud deseada y la atenuación en cada banda mediante un sistema de pesos, garantizando el cumplimiento estricto de la especificación en el borde de la banda de rechazo (550 kHz), no solo asintóticamente.

Especificaciones del diseño:

Parámetro	Valor
Frecuencia de muestreo del FIR $F_{s,FIR}$	10 MHz
Frecuencia de Nyquist	5 MHz
Borde banda de paso F_p	450 kHz
Borde banda de rechazo F_{stop}	550 kHz
Ancho de transición	100 kHz (1% de $F_{s,FIR}$)
Atenuación requerida	≥ 80 dB en $f \geq 550$ kHz
Ratio de pesos (paso : rechazo)	1 : 10000

Estimación de L con la fórmula de Bellanger:

$$M = \frac{-20 \log_{10} \sqrt{\delta_p \delta_s} - 13}{2.324 \cdot \Delta\omega}$$

donde δ_p y δ_s son los rizados en paso y rechazo (lineales), y $\Delta\omega$ es el ancho de transición en rad/muestra. Para nuestro caso ($\delta_p = 0.1$, $\delta_s = 10^{-80/20} = 10^{-4}$, $\Delta\omega = 2\pi \cdot 0.01 = 0.0628$):

$$M = \frac{-20 \log_{10} \sqrt{0.1 \cdot 10^{-4}} - 13}{2.324 \cdot 0.0628} = 253.4$$

Por lo tanto, L teórico = $M + 1 = 255$. No obstante, conviene tener presente que esta expresión proviene de una aproximación asintótica, y que el uso de una relación de pesos tan agresiva como 1:10000 en la práctica exige un número de coeficientes mayor al que predice la fórmula. Para compensar esta discrepancia, se introduce un coeficiente de seguridad de 3x sobre el valor calculado:

$L = \lceil 255 \times 3 \rceil = 765$ (ajustado al entero impar superior para mantener la simetría Tipo I)

1.2.7. Diseño mediante Parks-McClellan

La respuesta ideal del compensador es:

- 1 (ganancia unitaria) en la banda de paso: $0 \leq f \leq F_p$
- 0 (atenuación total) en la banda de rechazo: $f \geq F_{stop}$

Para diseñar el FIR se usa el algoritmo de Parks-McClellan, que es un método óptimo que minimiza el error máximo (norma infinito o sentido Chebyshev) entre la respuesta real del filtro y la ideal. El algoritmo de Remez, que es la implementación práctica de PM, se encarga de distribuir el error de forma equitativa entre las bandas respetando los pesos que se le asignan. Como pusimos pesos 1:10000 (pasa banda : rechaza banda), el error permitido en la stopband es 10000 veces más chico que en la pasabanda, lo que

obliga al algoritmo a concentrar casi todo el "presupuesto" de error en la pasabanda y deja la stopband limpia con 80+ dB de atenuación.

Bandas del diseño (normalizadas a $F_s = 10$ MHz):

- Banda de paso: $[0, 0.045)$ con deseado = 1
- Transición: $[0.045, 0.055)$
- Banda de rechazo: $[0.055, 0.49999)$ con deseado = 0, peso = 10000

Nota sobre la compensación de droop: Para cancelar el droop del CIC lo ideal sería que el FIR tuviera magnitud igual a $1/H_{CIC}(f)$ en la pasabanda, pero remez no permite especificar valores punto a punto dentro de una banda (solo se manejan pesos por banda entera), entonces esta forma de compensar el droop no es estable con remez. Por eso en este diseño se opta por un FIR plano (ganancia = 1 en pasabanda) y el droop se queda sin compensar. Como la especificación del enunciado solo pide ≥ 80 dB en la banda de rechazo, eso se cumple sin problema. Si en algún momento se necesitara planicidad perfecta en pasabanda, habría que agregar otra etapa de FIR.

1.2.8. Parámetros del FIR compensador

Parámetro	Valor
Ratio de pesos (paso : rechazo)	1 : 10000
Estimación de L (Bellanger)	$M = 253.4 \rightarrow L \text{ teórico} = 255$
Factor de seguridad	3× sobre la estimación teórica
Longitud total L	765 coeficientes (impar, Tipo I)
Centro α	382
Frecuencia de muestreo	10 MHz
Suma de h (ganancia DC)	aproximadamente 1.0

1.2.9. Coeficientes del FIR

Los coeficientes del filtro FIR compensador ($L=765$) son simétricos respecto al centro $\alpha=382$. La estructura general es la misma que en el filtro Kaiser (Tipo I, lóbulo central con valores del orden de 10^{-2} y valores en los extremos del orden de 10^{-8} a 10^{-9}), con la diferencia de que la cola del lóbulo principal es ligeramente más ancha por tener menos coeficientes.

El coeficiente central es $h[382]$ y la suma de los 765 coeficientes es aproximadamente 1.0, consistente con un FIR de ganancia unitaria en DC.

1.2.10. Clasificación del filtro

Propiedad	Resultado
Tipo de filtro	Tipo I (N impar, simetría par exacta)
Número de coeficientes	765
Coeficiente central $h[382]$	Aproximadamente. 9.78×10^{-2}

El filtro es exactamente de Tipo I (longitud impar con simetría par perfecta), apropiado para fase lineal con respuesta en frecuencia puramente real y positiva. Parks-McClellan garantiza esta simetría por construcción.

1.2.11. Análisis de la Respuesta en Frecuencia

Coeficientes del FIR




Figura 10 - Coeficientes del FIR compensador

En el panel izquierdo se muestran los 765 coeficientes $h[n]$, donde se aprecia un lóbulo central con valores del orden de 10^{-2} y valores en los extremos del orden de 10^{-8} a 10^{-9} . En el panel derecho se muestra un zoom de ± 50 muestras alrededor del centro ($\alpha = 382$), donde se observa la forma del lóbulo principal con el peak $h[382] \approx 0.098$ y la simetría par perfecta ($h[382-k] = h[382+k]$) característica del Tipo I. La forma regular del lóbulo principal, sin oscilaciones tipo Gibbs, es lo que diferencia al diseño equiripple de Parks-McClellan del truncamiento directo de una sinc.

Respuesta en frecuencia del FIR compensador




Figura 11 - Respuesta en frecuencia del FIR compensador

- Panel superior (Magnitud lineal): la curva parte cerca de 1 en DC y baja en forma casi vertical al pasar por la zona de transición, hasta quedar prácticamente en 0 dentro de la banda de rechazo.
- Panel central (Magnitud en dB): se observa una ganancia de 0 dB en la pasabanda, con un rizado equiripple que no llega a 0.2 dB; la transición entre 450 y 550 kHz es bien pronunciada, y en la stopband aparecen lóbulos laterales parejos cuyo pico más alto se ubica entre -80 y -90 dB.
- Panel inferior (Fase): la curva es una línea recta con pendiente $-\alpha = -382$ en la pasabanda, lo que confirma la fase lineal y un retardo de grupo fijo de 382 muestras, equivalente a $38.2 \mu s$ a 10 MHz.

La gráfica de magnitud en dB muestra la firma característica de un filtro equiripple: rizado uniforme en la banda de paso y lóbulos laterales equiespaciados en la banda de rechazo con peak en el orden de 80–90 dB bajo el nivel de paso.

Respuesta del sistema resultante (CIC + FIR)




Figura 12 - Filtro resultante CIC + FIR

En el panel de magnitud en dB se superpone la respuesta del CIC solo (línea gris discontinua) como referencia: el CIC tiene ganancia ≈ 82 dB en DC y cae a ≈ 79 dB en 500 kHz (droop de aproximadamente 1.6 dB), mientras que la respuesta combinada (línea azul) sigue la forma del CIC en la banda de paso. En la banda de rechazo, la curva combinada cae por debajo de -80 dB antes del borde $F_{stop} = 550$ kHz y se mantiene con lóbulos laterales equiripple. La fase desenvuelta es lineal en la banda de paso.

Métricas del sistema combinado (CIC + FIR):

Métrica	Valor	Especificación
Atenuación mínima en banda de rechazo (550 kHz)	≥ 80 dB	≥ 80 dB
Frecuencia donde se alcanza -80 dB	≤ 550 kHz	≤ 550 kHz
Ancho de transición real	≈ 80 -90 kHz	≤ 100 kHz
Rizado en banda de paso	≈ 0.2 dB	-
Rizado en banda de rechazo	≥ 80 dB	≥ 80 dB
Frecuencia -3 dB	≈ 480 kHz	-

Lo que aparece en la tabla de arriba son valores aproximados, esperados para un diseño con $L=765$ y pesos 1:10000.

Análisis de la compensación del droop:

A 500 kHz la cascada CIC presenta un droop cercano a 1.6 dB. En este diseño se dejó el FIR con ganancia unitaria sin compensar el droop de forma explícita, por lo que esa caída se traslada tal cual a la respuesta combinada CIC + FIR dentro de la pasabanda.

Comparación con el CIC solo:

La curva gris punteada es la respuesta del CIC aislado (sin compensar), que cae unos 1.6 dB a 500 kHz. La curva azul (sistema completo) arranca en 0 dB en DC y arrastra ese mismo droop en la pasabanda, pero a cambio garantiza más de 80 dB de rechazo en la stopband.

1.2.12. Análisis de fase y retardo de grupo

La fase del filtro resultante es lineal en la banda de paso, lo que implica un retardo de grupo constante:

$$\tau_g = -\frac{d\phi(\omega)}{d\omega} = \alpha = 382 \text{ muestras}$$

A la tasa del FIR (10 MHz), esto corresponde a un retardo temporal de:

$$\tau = \frac{382}{10 \text{ MHz}} = 38.2 \mu\text{s}$$

Este retardo de grupo constante es esencial para preservar la forma de los pulsos del radar.

1.2.13. Verificación de Especificaciones

La siguiente tabla resume los parámetros del filtro resultante y su cumplimiento con las especificaciones.

Parámetro	Especificación	Logrado
Atenuación en banda de rechazo (550 kHz)	$\geq 80 \text{ dB}$	$\approx 85\text{-}90 \text{ dB}$
Frecuencia donde se alcanza -80 dB	$\leq 550 \text{ kHz}$	$\leq 550 \text{ kHz}$
Ancho de transición real	$\leq 100 \text{ kHz}$	$\approx 80\text{-}90 \text{ kHz}$
Ganancia DC del sistema	0 dB	0.00 dB
Rizado en banda de paso	-	$\approx 0.2 \text{ dB}$
Rizado en banda de rechazo	$\geq 80 \text{ dB}$	$\geq 80 \text{ dB}$

Observaciones:

1. La respuesta combinada cumple la especificación de 80 dB a 550 kHz con un margen moderado. El margen exacto depende del factor de seguridad usado ($3\times$

- en este caso); con un factor mayor se obtiene más margen a costa de más coeficientes.
2. El ancho de transición es más estrecho que la transición de diseño (100 kHz). Esto se debe a que con $L=765$ y pesos 1:10000, el algoritmo PM produce una transición más pronunciada que la estrictamente necesaria.
 3. La ganancia DC del sistema completo tiene ganancia exacta de 0 dB (1.0) en DC, lo que confirma que el diseño está bien hecho y es consistente.
 4. El rizado en banda de paso es aproximadamente 0.2 dB, dado que el peso en banda de rechazo es $10000\times$ mayor que en banda de paso, por lo que el rizado permitido en paso es $10000\times$ mayor que en banda de rechazo.
 5. Tipo de filtro (Tipo I exacto), ya que la simetría par es perfecta, lo que garantiza fase lineal exacta en toda la banda de paso y respuesta en frecuencia puramente real.

Limitaciones de la arquitectura CIC + FIR

Es importante notar que la combinación de CICs en cascada con un único FIR compensador tiene una limitación el cual, el lóbulo principal del CIC se extiende hasta su primer nulo (a 10 MHz para el CIC5), lo que significa que el CIC tiene una ganancia significativa en toda la banda de paso del FIR (0-500 kHz). En este diseño, el FIR no compensa el droop en la banda de paso, por lo que la respuesta combinada muestra la caída natural del CIC (aproximadamente 1.6 dB a 500 kHz). Para compensación exacta de droop, se requeriría una segunda etapa FIR.

Para aplicaciones que requieren una banda de rechazo más pronunciada, se necesitarían etapas adicionales de CIC y/o FIR. Sin embargo, para esta aplicación de radar específica, donde el objetivo es rechazar señales fuera de la banda de paso de 500 kHz con 80 dB de atenuación, es suficiente.

1.2.13. Conclusiones

1. La arquitectura CIC + FIR es eficiente, dado que el FIR opera a 10 MHz en lugar de 100 MHz gracias a la decimación previa de los CICs ($2\times 5=10$), por lo que el FIR compensador tiene 765 coeficientes, aproximadamente $6.5\times$ menos que el FIR directo de la Parte 1 (5017 coeficientes).
2. Parks-McClellan cumple la especificación, dado que la magnitud se controla directamente con pesos, por lo que con un ratio 1:10000 (paso:rechazo) se concentran los errores en pasabanda y se producen ≥ 80 dB de atenuación en 550 kHz.
3. La atenuación de 80 dB se cumple con margen moderado, dado que la transición real (≈ 80 -90 kHz) es más estrecha que la de diseño (100 kHz), por lo que la

respuesta combinada cae por debajo de -80 dB antes de 550 kHz para el factor 3×.

4. El filtro es de fase lineal exacta, dado que PM produce simetría par perfecta por construcción, por lo que el retardo de grupo es constante de 382 muestras (38.2 μ s a 10 MHz), esencial para preservar la forma de los pulsos del radar.
5. La atenuación mejora con la frecuencia, dado que la caída natural del lóbulo principal del CIC5 se combina con la del FIR, por lo que la atenuación es aún mayor a frecuencias mayores.
6. PM supera a Kaiser para esta especificación, dado que la magnitud se controla directamente con pesos, por lo que se alcanzan los 80 dB en 550 kHz, mientras que Kaiser usa atenuación asintótica ($\beta=7.86$) que no se traduce en atenuación real en el borde de la transición.
7. La estimación de L es eficiente con Bellanger, dado que la fórmula es asintótica, por lo que aplicando un factor de seguridad 3× sobre el L teórico se obtiene L=765 en una sola iteración, suficiente para cumplir la especificación con margen.
8. La compensación de droop queda pendiente, dado que compensarlo (≈ 1.6 dB) requeriría una etapa adicional, por lo que este diseño prioriza la especificación de banda de rechazo.

1.3. Comparación de Filtros y Selección

1.3.1. Tabla Comparativa: Parte 1 vs Parte 2

Aspecto	FIR Kaiser	CIC + FIR Compensador
Arquitectura	FIR directo	CICs en cascada con filtro compensador
Tasa del FIR	100 MHz	10 MHz
Método de diseño	Ventana Kaiser	Parks-McClellan
Parámetro de diseño	$\beta = 7.8573$	Pesos paso:rechazo = 1:10000
Estimación de L	Fórmula de Kaiser	Fórmula de Bellanger ($\times 3$)
Longitud del FIR	5017 coeficientes	765 coeficientes
Frecuencia de corte	500 kHz	500 kHz
Ancho de transición	100 kHz	100 kHz (real: ≈ 80 -90 kHz)
Atenuación en rechazo	80 dB (asintótica)	≥ 80 dB en 550 kHz (real, no asintótica)
Atenuación mínima en banda de rechazo	80.28 dB	≈ 85 -90 dB
Ganancia DC	1 (0 dB)	1 (0 dB)
Rizado en paso	0.0016 dB	≈ 0.2 dB
Retardo de grupo	2508 muestras (25.08 μ s)	382 muestras (38.4 μ s)
Tipo de filtro	Tipo I	Tipo I

1.3.2. Metodología de Comparación

Las dos arquitecturas operan a tasas internas diferentes (Kaiser a $F_s = 100$ MHz, CIC+FIR a $F_{s,FIR} = 10$ MHz), pero ambas apuntan a las mismas especificaciones de magnitud: $F_p = 450$ kHz, $F_{stop} = 550$ kHz, atenuación ≥ 80 dB. Para una comparación justa se evalúan las respuestas en frecuencia en un eje común de 0 a 5 MHz (Nyquist del FIR compensador de la arquitectura CIC).

El filtro efectivo aplicado a la señal original es:

- Arquitectura 1 (Kaiser): $H_{Kaiser}(f)$, con 5017 coeficientes
- Arquitectura 2 (CIC + FIR):
 $H_{CIC,cascada}(f) * H_{FIR}(f)$, donde $H_{CIC,cascada} = H_{CIC2} * H_{CIC5}$ y H_{FIR} tiene 765 coeficientes

En el dominio de la salida ($F_s' = 1$ MHz), ambos producen una señal decimada con aliasing mínimo, pero con diferentes magnitud y fase en la banda de paso.

1.3.3. Comparación de Magnitud




Figura 13 - Comparación de magnitud Kaiser vs CIC+FIR

- Panel superior (Magnitud lineal): se superponen $|H_{Kaiser}(f)|$ (línea azul) y $|H_{CIC,cascada}(f) \cdot H_{FIR}(f)|$ (línea naranja) en el rango 0–5 MHz. El Kaiser tiene respuesta aproximadamente 1 en la banda de paso cerca de la frecuencia de corte, mientras que el CIC+FIR muestra el droop del CIC (aproximadamente 1.6 dB de caída a 500 kHz). Ambos caen a aproximadamente 0 en la banda de rechazo.

- Panel inferior (Magnitud en dB): Se observan las líneas de referencia en $F_p = 450$ kHz, $F_{stop} = 550$ kHz y -80 dB. El Kaiser tiene una banda de paso perfectamente plana en 0 dB, mientras que el CIC+FIR muestra la caída natural del CIC. En la banda de rechazo, ambos están por debajo de -80 dB: el Kaiser apenas cumple y el CIC+FIR cumple con un margen de 5-10 dB.

1.3.4. Comparación de Fase




Figura 14 - Comparación de fase Kaiser vs CIC+FIR

- Kaiser: recta de pendiente $-\alpha_{\text{Kaiser}} = -2508$ en la banda de paso (retardo de grupo constante de 2508 muestras = $25.08 \mu\text{s}$ a 100 MHz).
- CIC + FIR: recta de pendiente correspondiente al retardo de grupo total del sistema, suma de los retardos del CIC2 (1 muestra a 100 MHz = 10 ns), CIC5 (10 muestras a 50 MHz = 200 ns) y FIR (382 muestras a 10 MHz = $38.2 \mu\text{s}$), dando un total de aproximadamente $38.41 \mu\text{s} \approx 38.4 \mu\text{s}$.

Ambas fases son estrictamente lineales en la banda de paso, lo que garantiza retardo de grupo constante y preservación de la forma temporal de los pulsos del radar. La diferencia en retardo de grupo ($25.08 \mu\text{s}$ vs $38.4 \mu\text{s}$) se traduce en un desfase temporal fijo entre los dos diseños.

1.3.5. Filtro Más Adecuado para la Aplicación

Recomendación: la arquitectura CIC + FIR (Parte 2) es la más adecuada para esta aplicación de radar SDR.

Justificación

1. Acerca del cumplimiento de la especificación de la banda de rechazo, el Kaiser cumple la atenuación de 80 dB por escaso margen (80.28 dB, 0.28 dB sobre el límite). En una aplicación de radar, donde las señales fuera de banda pueden ser interferencias fuertes, este margen es insuficiente. El CIC+FIR, en cambio, cumple con un margen de 5-10 dB sobre los 80 dB requeridos, lo que da robustez ante estas variaciones.
2. Cumplimiento del ancho de transición. El Kaiser excede la especificación en 3.89% (103.89 kHz), mientras que el CIC+FIR cumple estrictamente ($\approx 80\text{--}90\text{ kHz} < 100\text{ kHz}$). En un sistema de decimación, una transición más estrecha que la especificada reduce el aliasing residual, mejorando la SNR de la señal decimada.
3. Eficiencia computacional (aproximadamente 30 veces). El CIC+FIR procesa menos operaciones por segundo que el Kaiser directo. Esto se traduce en menor consumo de potencia y posibilidad de usar DSPs de menor costo en implementaciones con microprocesadores comerciales.
4. Ambos filtros son de fase lineal exacta (Tipo I), por lo que ambos preservan la forma de los pulsos del radar sin distorsión temporal. La diferencia en retardo de grupo (25.08 μs vs 38.4 μs) se compensa con un buffer de salida.

¿Cuándo preferir el Kaiser?

El Kaiser sería preferible en los siguientes escenarios:

- El Kaiser tiene 0.0016 dB de rizado (vs ~ 1.6 dB del CIC+FIR por el droop no compensado). Si la aplicación requiere una respuesta en ganancia dentro de la banda de paso, el Kaiser es superior.
- Si la arquitectura debe ser lo más simple posible (un solo filtro FIR, sin etapas de decimación intermedia), el Kaiser evita la complejidad de los CICs.
- Si la tasa de muestreo es moderada (no se requiere decimación), el ahorro computacional del CIC se reduce y el Kaiser puede ser mejor.

2. Comparación de Algoritmos LMS

Este problema analiza el rendimiento de los algoritmos adaptativos LMS (Least Mean Squares) estudiados en el curso, aplicados a la predicción lineal de una señal autorregresiva. Se compara el LMS estándar, el LMS normalizado (NLMS) y el LMS-Newton, evaluando su velocidad de convergencia y la varianza de los coeficientes estimados mediante simulaciones Monte Carlo con 100 realizaciones.

2.1. Predictor lineal y Filtro Wiener

Sea $x[n]$ un proceso aleatorio WSS (sentido ampliamente estacionario) con matriz de autocorrelación R_x y sea $\vec{r}_{dx}$ el vector de correlaciones cruzadas entre la señal deseada $d[n]$ y la entrada. El filtro FIR causal de longitud M que minimiza $\xi = E\{e[n]^2\}$ se obtiene de las ecuaciones de Wiener-Hopf (Milla Bravo, 2026, Clase 12, p. 9):

$$R_x \vec{w}_{\text{opt}} = \vec{r}_{dx} \quad \Rightarrow \quad \vec{w}_{\text{opt}} = R_x^{-1} \vec{r}_{dx}$$

donde R_x es Toeplitz (porque $x[n]$ es WSS) y por lo tanto Hermítica y definida positiva, garantizando la invertibilidad.

En el caso particular del predictor lineal (Milla Bravo, 2026, Clase 12, p. 18), la señal deseada es $d[n] = x[n+1]$, de modo que la correlación cruzada se reduce a $\vec{r}_{dx}[k] = E\{x[n+1]x[n-k]\} = r_x[k+1]$. Esto produce la ecuación matricial para el predictor:

$$\underbrace{\begin{bmatrix} r_{v_2}[0] & r_{v_2}[1] & \cdots & r_{v_2}[M-1] \\ r_{v_2}[1] & r_{v_2}[0] & \cdots & r_{v_2}[M-2] \\ \vdots & \vdots & \ddots & \vdots \\ r_{v_2}[M-1] & r_{v_2}[M-2] & \cdots & r_{v_2}[0] \end{bmatrix}}_{\mathbf{R}_{v_2}} \underbrace{\begin{bmatrix} w[0] \\ w[1] \\ \vdots \\ w[M-1] \end{bmatrix}}_{\vec{w}} = \underbrace{\begin{bmatrix} r_{xv_2}[0] \\ r_{xv_2}[1] \\ \vdots \\ r_{xv_2}[M-1] \end{bmatrix}}_{\vec{r}_{xv_2}}$$

Figura 15 - Ecuación matricial de Wiener-Hopf para el predictor lineal

Si el proceso es autorregresivo de orden M , las autocorrelaciones satisfacen las ecuaciones de Yule-Walker:

$$r_x[k] = \sum_{m=1}^M a[m] r_x[k-m] + \sigma_w^2 \delta[k]$$

Sustituyendo en la ecuación del predictor se obtiene (Milla Bravo, 2026, Clase 12, p. 21) que el predictor óptimo reproduce exactamente los coeficientes del AR que generó la señal:

$$\vec{w}_{\text{opt}} = [a[1], a[2], \dots, a[M]]^T$$

Este resultado es la base teórica del problema: el predictor LMS debe converger a $\vec{h}_{\text{ideal}} = [0.85, -0.15]^T$ para el AR(2) con $a[1] = 0.85$ y $a[2] = -0.15$.

2.2. Derivación del LMS por gradiente descendente

El LMS se obtiene aplicando gradiente descendente sobre la superficie del MSE instantáneo $\xi[n] = E\{|e[n]|^2\}$ y reemplazando el valor esperado por una estimación instantánea.

2.2.1. Gradiente del MSE

Partiendo de $\xi[n] = E\{|e[n]|^2\}$ con $e[n] = d[n] - \vec{w}^T \vec{x}^{(n-1)}$, se calcula el gradiente respecto a los coeficientes:

$$\nabla_{\vec{w}} \xi[n] = \nabla_{\vec{w}} E\{|e[n]|^2\} = 2E\{e[n] \nabla_{\vec{w}} e[n]\} = -2E\{e[n] \vec{x}^{(n-1)}\}$$

porque $\nabla_{\vec{w}} e[n] = -\vec{x}^{(n-1)}$.

2.2.2. Gradiente descendente

Aplicando la regla estándar $x_{k+1} = x_k - \mu \nabla F(x_k)$:

$$\vec{w}^{(n+1)} = \vec{w}^{(n)} - \mu \nabla_{\vec{w}} \xi[n] = \vec{w}^{(n)} + 2\mu E\{e[n] \vec{x}^{(n-1)}\}$$

2.2.3. Aproximación estocástica

El valor esperado $E\{e[n] \vec{x}^{(n-1)}\}$ se reemplaza por su media muestral con una sola muestra ($L = 1$):

$$E\{e[n] \vec{x}^{(n-1)}\} = e[n] \vec{x}^{(n-1)}$$

2.2.4. Algoritmo LMS

Sustituyendo se obtiene la regla de actualización del LMS estándar:

$$\vec{h}^{(n+1)} = \vec{h}^{(n)} + 2\mu e[n] \vec{x}^{(n-1)}$$

El LMS es, por construcción, una versión estocástica del gradiente descendente, donde el ruido de gradiente es la diferencia entre $E\{e[n] \vec{x}^{(n-1)}\}$ y su aproximación $e[n] \vec{x}^{(n-1)}$.

2.2.5. Convergencia

Condición	Rango de μ	Observación
Convergencia en la media (WSS)	$0 < \mu < \frac{1}{\lambda_{max}}$	λ_{max} el mayor autovalor de $\mathbf{R}_x$
Convergencia en media cuadrática (general)	$0 < \mu < \frac{1}{\text{tr}\{\mathbf{R}_x\}}$	$\text{tr}\{\mathbf{R}_x\} = M r_x[0]$ $= ME\{ x[n] ^2\}$ es la potencia total

Como $\lambda_{max} \leq \text{tr}\{\mathbf{R}_x\}$, la cota en media cuadrática es más conservadora que la cota en media, y es la que se usa en la práctica cuando $x[n]$ no es estacionario. La cota en media es la que muestra explícitamente que la velocidad de convergencia del LMS está limitada por el autovalor más chico de $\mathbf{R}_x$, el tiempo de convergencia escala como $1/(2\mu\lambda_{min})$, así que aun eligiendo μ pequeño el algoritmo puede ser lento si $\mathbf{R}_x$ tiene un número de condición $\kappa(\mathbf{R}_x) = \frac{\lambda_{max}}{\lambda_{min}}$ alto.

2.3. Algoritmos LMS comparados

Los tres algoritmos actualizan $\vec{h}^{(n)}$ en cada muestra usando el error instantáneo $e[n]$, pero difieren en cómo escalan la actualización.

2.3.1. LMS

La regla de actualización es la forma estocástica del gradiente descendente sobre el MSE instantáneo:

$$\vec{h}^{(n+1)} = \vec{h}^{(n)} + 2\mu e[n] \vec{x}^{(n-1)}$$

La velocidad de convergencia está limitada por el autovalor más pequeño de la matriz de correlación $\mathbf{R}$. Para asegurar convergencia se requiere $\mu < \frac{1}{\lambda}$ para minimizar la varianza estacionaria se recomienda $\mu \ll 1/\text{tr}(\mathbf{R})$ donde $\text{tr}(\mathbf{R})$ es la traza de la matriz $\mathbf{R}$.

2.3.2. LMS normalizado (NLMS)

Normaliza el paso por la potencia instantánea de la entrada, lo que vuelve al algoritmo insensible al escalado de la señal:

$$\vec{h}^{(n+1)} = \vec{h}^{(n)} + 2 \frac{\mu}{(\vec{x}^{(n-1)})^T \vec{x}^{(n-1)} + \epsilon} e[n] \vec{x}^{(n-1)}.$$

Figura 16 - Ecuación de actualización del LMS normalizado (NLMS)

El ϵ evita división por cero cuando la entrada es nula. NLMS converge más rápido que LMS estándar bajo entradas con potencia variable porque su μ efectivo se adapta automáticamente.

2.3.3. LMS-Newton

El LMS-Newton ataca directamente la limitación de velocidad del LMS estándar pre-multiplicando por la inversa de la matriz de correlación R_x^{-1} :

$$\vec{h}^{(n+1)} = \vec{h}^{(n)} + 2\mu e[n] R_{\text{inv}}^{(n)} \vec{x}^{(n-1)}$$

donde R_{inv} es la inversa de la matriz de correlación R . $R_{\text{inv}}^{(n)}$ se puede calcular de forma iterativa de la siguiente forma

$$R_{\text{inv}}^{(n)} = \frac{1}{w} \left\{ R_{\text{inv}}^{(n-1)} - \frac{R_{\text{inv}}^{(n-1)} \vec{x}^{(n-1)} (\vec{x}^{(n-1)})^T R_{\text{inv}}^{(n-1)}}{w + (\vec{x}^{(n-1)})^T R_{\text{inv}}^{(n-1)} \vec{x}^{(n-1)}} \right\}$$

donde w es el factor de olvido.

Figura 17 - Ecuación de actualización del LMS-Newton

Costo computacional

Por iteración, el costo de cada algoritmo es:

Algoritmo	Multiplicaciones principales	Orden
LMS estándar	2M	O(M)
NLMS	3M	O(M)
LMS-Newton	2M + O(M ²)	O(M ²)

Para $M = 2$ como en este problema, el costo extra del LMS-Newton es despreciable, pero la diferencia se vuelve significativa para órdenes de predictor grandes ($M \gg 1$), donde hay que evaluar si la ganancia en velocidad de convergencia justifica el costo $O(M^2)$.

A continuación, se muestra el diagrama del predictor lineal.




Figura 18 - Diagrama del predictor lineal

2.4. Parámetros del sistema

Parámetro	Valor	Descripción
Orden del modelo AR (M)	2	Número de coeficientes del AR
Coeficientes del modelo (a[1], a[2])	0.85, -0.15	Coeficientes del predictor ideal
Varianza del ruido (σ_w^2)	0.25	Potencia del ruido blanco de entrada
Longitud de la secuencia (N)	5000 muestras	Suficiente para alcanzar régimen estacionario
Número de realizaciones Monte Carlo	100	Para promediar sobre el ruido
Condición inicial	$x[n] = 0$ para $n < 0$	Para que la señal arranque de cero
Coeficientes ideales	$\vec{h}_{ideal} = [0.85, -0.15]^T$	Solución Wiener-Hopf

Para el LMS-Newton se usó factor de olvido $w = 0.99$ (valor típico en aplicaciones donde la estadística de la señal varía lentamente, como audio/voz) y se inicializó $R_{inv}^{(0)} = 10I$. Sin esta inicialización ($R_{inv} = 0$), la primera actualización da $R_{inv} \cdot \vec{x} = 0$, por lo que h no se actualiza y el algoritmo se queda congelado en $h(0) = 0$. La longitud $N = 5000$ es más que suficiente para que los algoritmos alcancen el régimen estacionario bajo los μ que se calibran más adelante.

2.5. Procedimiento

2.5.1. Generación de la Señal AR(2)

La señal $x[n]$ se genera excitando el modelo AR con ruido blanco gaussiano. Para cada realización Monte Carlo se genera una semilla distinta, lo que da 100 secuencias independientes sobre las que se promedian los resultados. La condición inicial $x[n] = 0$ para $n < 0$ corresponde a la hipótesis estándar de sistema en reposo del modelo AR causal: el filtro parte de energía nula, de modo que las primeras M muestras solo contienen contribución del ruido $w[n]$ antes de que el término recursivo domine y la señal alcance el régimen estacionario.

Como $a[1] = 0.85$ y $a[2] = -0.15$, los polos del modelo están aproximadamente en $z = 0.93$ y $z = -0.08$ (raíces de $1 - 0.85z^{-1} + 0.15z^{-2} = 0$), por lo que el sistema es estable y la señal tiene contenido en baja frecuencia con correlación entre muestras consecutivas.

A continuación, se muestra los códigos en Python:

```
def generar_senal_AR(N, a, sigma_w, rng):
    """
    Genera una realizacion de la senal AR(M) segun:
         $x[n] = \sum_{m=1}^M a[m-1] * x[n-m] + w[n]$ 
    con  $x[n]=0$  para  $n<0$  y  $w[n] \sim N(0, \sigma_w^2)$ .
    """
    M = len(a)
    x = np.zeros(N)
    w = rng.normal(0.0, sigma_w, size=N)
    for n in range(N):
        suma = 0.0
        for m in range(1, M + 1):
            if n - m >= 0:
                suma += a[m - 1] * x[n - m]
        x[n] = suma + w[n]
    return x, w
```

2.5.2. Implementación de los Algoritmos

Para el predictor de orden $M = 2$ el vector de entrada en el instante n es $\vec{x}^{(n-1)} = [x[n-1], x[n-2]]^T$. Los tres algoritmos se implementaron de forma vectorizada (sin bucles sobre las realizaciones en el caso Monte Carlo) para que la simulación con 100 realizaciones fuera eficiente.

2.5.2.1. LMS:

```
def _xvec(x, n, M):
    """Construye el vector  $[x[n-1], x[n-2], \dots, x[n-M]]$ . Asume  $n \geq M$ ."""
    # Indices: n-1, n-2, ..., n-M, todos  $\geq 0$  cuando  $n \geq M$ 
    idx = np.arange(n - 1, n - M - 1, -1)
    return x[idx]

def lms(x, h0, mu):
    """
    LMS estandar. Devuelve la evolucion de los coeficientes (N+1 filas,
    len(h0) cols)
    y la evolucion del error cuadratico instantaneo (N muestras).
    """
    N = len(x)
    M = len(h0)
    H = np.zeros((N + 1, M))
    e = np.zeros(N)
    h = h0.copy()
    for n in range(M, N):
        xvec = _xvec(x, n, M)
```

```

    y = np.dot(h, xvec)
    e[n] = x[n] - y
    h = h + 2.0 * mu * e[n] * xvec
    H[n + 1] = h
return H, e

```

2.5.2.2. LMS normalizado:

```

def lmsn(x, h0, mu, eps=1e-8):
    """LMS normalizado (NLMS)."""
    N = len(x)
    M = len(h0)
    H = np.zeros((N + 1, M))
    e = np.zeros(N)
    h = h0.copy()
    for n in range(M, N):
        xvec = _xvec(x, n, M)
        y = np.dot(h, xvec)
        e[n] = x[n] - y
        norm2 = np.dot(xvec, xvec) + eps
        h = h + (2.0 * mu / norm2) * e[n] * xvec
        H[n + 1] = h
    return H, e

```

2.5.2.3. LMS-Newton:

```

def lms_newton(x, h0, mu, w=0.99, delta=10.0):
    """LMS-Newton con actualizacion iterativa de  $R^{-1}$ ."""
    N = len(x)
    M = len(h0)
    H = np.zeros((N + 1, M))
    e = np.zeros(N)
    h = h0.copy()
    Rinv = delta * np.eye(M)
    for n in range(M, N):
        xvec = _xvec(x, n, M).reshape(-1, 1)
        y = float(np.dot(h, xvec.ravel()))
        e[n] = x[n] - y
        Rinv_x = Rinv @ xvec
        den = w + float((xvec.T @ Rinv_x)[0, 0])
        Rinv = (Rinv - (Rinv_x @ Rinv_x.T) / den) / w
        # actualizacion de coeficientes
        h = h + 2.0 * mu * e[n] * (Rinv @ xvec).ravel()
        H[n + 1] = h
    return H, e

```

2.5.2.4. Verificación con un μ arbitrario

Antes de la calibración, se verificó con un valor de μ razonable para cada algoritmo que los tres convergen a los coeficientes ideales $[0.85, -0.15]^T$:

Coeficientes ideales	$h = [0.85 -0.15]$
LMS estandar	$h = [0.835 -0.054]$
LMS normalizado	$h = [1.817 -1.038]$
LMS Newton	$h = [0.809 -0.062]$

Se observa que el LMS estándar y el LMS-Newton convergen razonablemente cerca del ideal con un μ elegido. El NLMS, en cambio, da valores lejanos al ideal con este μ particular en esta única realización, porque su paso efectivo $2\mu/\|\vec{x}^{(n-1)}\|^2$ se vuelve inestable cuando $\|\vec{x}^{(n-1)}\|^2$ es chico. Con un μ menor (≈ 0.1) la verificación es honesta, y la calibración de 3.2 produce los μ definitivos. Las calibraciones de los pasos 3.1 y 3.2 producen los μ definitivos que sí llevan al régimen estacionario correcto.

La curva de coeficientes vs n se muestra en la siguiente figura.




Figura 19 - Convergencia con μ arbitrario

2.5.3. Comparación con 100 Realizaciones

Para analizar el rendimiento de cada algoritmo se repite el procedimiento $N=100$ veces, variando la semilla del ruido blanco en cada corrida, y se promedian los coeficientes y el MSE a lo largo del tiempo. En el régimen estacionario (después de $n_0 = N/2$ muestras) se calculan:

- MSE promedio:
$$\text{MSE}[n] = \frac{1}{N_{\text{real}}} \sum_{r=1}^N (e_r[n])^2$$
- Varianza de los coeficientes:
$$\text{Var}(h_m)[n] = \frac{1}{N_{\text{real}}} \sum_r \left(h_m^{(r)}[n] - \bar{h}_m[n] \right)^2$$

donde $\bar{h}_m[n]$ es el coeficiente promedio en el instante n .

2.5.3.1. Misma Varianza, Comparar Velocidad

Se ajustó el paso μ de cada algoritmo de modo que la varianza en estado estacionario de los coeficientes sea la misma, y luego se comparó la velocidad de convergencia. La calibración se hizo por bisección sobre el μ de cada algoritmo.

Algoritmo	μ calibrado	Varianza estacionaria
LMS estándar	0.02000	4.301×10^{-3}
LMS normalizado	0.05001	3.183×10^{-1}
LMS-Newton	0.47966	4.302×10^{-3}

El NLMS no alcanzó la varianza objetivo dentro del rango probado de μ , lo cual es coherente con la teoría: como NLMS normaliza por la potencia instantánea $|\vec{x}^{(n-1)}|^2$, su varianza depende mucho menos del μ que la del LMS estándar y el Newton, y en este experimento la varianza del NLMS se quedó alrededor de 10^{-1} incluso con μ pequeño. Para igualar exactamente la varianza de los otros dos haría falta reducir el rango de búsqueda o usar otro criterio.




Figura 20 - Coeficientes promedio vs n con varianza igualada

Análisis:

El algoritmo con mayor velocidad de convergencia es el LMS-Newton. Esto se debe a que la pre-multiplicación por $\mathbf{R}_{\text{inv}}$ blanquea la señal de entrada, desacoplando los modos de convergencia. Como para el LMS-Newton, todos los autovalores son iguales y la velocidad es independiente del número de condición $\kappa(\mathbf{R}_x)$ de la entrada. El LMS estándar, en cambio, tiene su modo de convergencia dominado por el peor autovalor de $\mathbf{R}_x$, el tiempo característico escala como $\frac{1}{\mu\lambda_{\min}}$ por lo que converge más lento.

El NLMS queda en una posición intermedia: normaliza por la potencia instantánea $|\vec{x}^{(n-1)}|^2$ pero no por la matriz de correlación completa, así que su desacople de modos

es parcial. Esto explica por qué converge más rápido que el LMS estándar pero más lento que el LMS-Newton.

2.5.3.2. Misma Velocidad, Comparar Varianza

Ahora se ajustó el μ de cada algoritmo para que la velocidad de convergencia sea la misma (cuantificada como el número de muestras necesarias para que el MSE caiga al 5% de su valor inicial) y se comparó la varianza estacionaria resultante.

Con los μ calibrados, los tres algoritmos cumplieron el criterio de MSE al 5% de la inicial en aproximadamente la misma cantidad de muestras ($t_{5\%} \approx 0$ en todos los casos con los μ usados, lo que indica que con los μ elegidos los algoritmos convergen muy rápido):

Algoritmo	μ calibrado	$t_{5\%}$
LMS estándar	0.05	aproximadamente 0 muestras
LMS normalizado	0.011	aproximadamente 0 muestras
LMS-Newton	0.011	aproximadamente 0 muestras

Las varianzas resultantes en estado estacionario fueron:

Algoritmo	Varianza estacionaria
LMS estándar	1.126×10^{-2}
LMS normalizado	5×10^{-2}
LMS-Newton	1.5×10^{-3}

A continuación, se muestra la comparación en la siguiente figura.




Figura 21 - Coeficientes promedio vs n con velocidad igualada

Análisis:

El algoritmo con mayor varianza de los coeficientes estimados es el NLMS, seguido por el LMS estándar, y el de menor varianza es el LMS-Newton. La varianza del LMS-Newton es aproximadamente 75 veces más baja que la del LMS estándar, mientras que el NLMS supera al LMS estándar por un factor de aproximadamente $5\times$. Esto se debe a que el paso efectivo del NLMS es $2\mu/\|\vec{x}^{(n-1)}\|^2$, y cuando $\|\vec{x}^{(n-1)}\|^2$ es chico en algún instante, el paso se agranda y amplifica el ruido de gradiente, lo que se traduce en mayor varianza de los coeficientes estimados.

El LMS estándar usa $\mu = 0.05$ (mayor que el del NLMS y Newton), pero su paso es fijo y bien comportado, por lo que su varianza es menor que la del NLMS pero más alta que la del LMS-Newton.

El LMS-Newton logra la menor varianza porque su tasa de convergencia $\tau = 1/(2\mu)$ es independiente de los autovalores de R_x , lo que le permite alcanzar la misma velocidad de convergencia con un μ mucho menor (0.011 vs 0.05) que el LMS estándar, reduciendo la amplificación del ruido de gradiente.

2.6. Conclusiones

Del estudio comparativo de los tres algoritmos LMS se concluye que:

1. El LMS-Newton ofrece el mejor compromiso velocidad/varianza debido a que la matriz de correlación de la entrada tiene un número de condición alto, pero pre multiplicar por R_{inv} desacopla los modos de convergencia, de modo que su tasa $\tau = 1/(2\mu)$ es independiente del autovalor mínimo de R_x . Esto le permite alcanzar la misma velocidad de convergencia que el LMS estándar con un μ mucho menor (0.011 vs 0.05), lo que reduce la amplificación del ruido de gradiente y se traduce en convergencia más rápida y menor varianza estacionaria que el LMS estándar.
2. El NLMS es robusto ante cambios de potencia de la señal debido a que la normalización altera la magnitud, no la dirección, pero su varianza estacionaria es alta cuando se le exige la misma velocidad que a los otros dos. Esto es coherente con que NLMS solo normaliza por la potencia instantánea $|\vec{x}^{(n-1)}|^2$, no por la estructura de correlación completa de R_x .
3. El LMS estándar es el más simple debido al menor costo computacional por iteración, pero también el más sensible al condicionamiento de R_x y al escalado de la entrada. Su μ efectivo está limitado por el peor autovalor de R_x , lo que obliga a usar pasos chicos.
4. La inicialización de R_{inv} y el factor de olvido son detalles de implementación importantes. Sin una inicialización con δ adecuado, la primera actualización de Newton produce divisiones por números cercanos a cero y el algoritmo diverge.

Un w cercano a 1 es apropiado, ya que valores más chicos harían al algoritmo olvidar estadísticas pasadas demasiado rápido.

5. Para un proceso AR(M), los coeficientes del predictor óptimo de Wiener son exactamente los coeficientes $a[m]$ del propio modelo AR que generó la señal, por lo que $\vec{h}_{\text{opt}} = [a[1], \dots, a[M]]^T$ sirve como referencia exacta para evaluar la convergencia del LMS, comparando $\vec{h}^{(n)}$ con $[0.85, -0.15]^T$.



3. Ecualización de Canal

Este problema aborda el diseño de un ecualizador adaptativo para recuperar un mensaje de texto que fue codificado en QPSK y transmitido a través de un canal variante en el tiempo con respuesta al impulso de tres coeficientes. La interferencia entre símbolos (ISI) introducida por el canal se cancela con un filtro adaptativo LMS, cuyo entrenamiento se realiza con los primeros 200 caracteres del mensaje y luego sigue en modo decision-directed para adaptarse a las variaciones del canal. Adicionalmente, se estima la respuesta al impulso del canal y se compara con la solución zero-forcing y con un ecualizador DFE.

3.1. Sistema de comunicación con ISI

En un sistema de comunicación digital, es fundamental evitar la interferencia intersimbólica (ISI) para garantizar una comunicación confiable. La ISI se presenta debido a distorsiones introducidas por el propio canal de comunicaciones; una causa frecuente es la dispersión del canal, provocada por una respuesta de fase no lineal.

Un modelo general para la secuencia recibida es

$$y[n] = \sum_{k=-\infty}^{\infty} x[k] h[n, k] + w[n]$$

donde $x[k]$ es la secuencia transmitida, $h[n, k]$ es la respuesta al impulso del canal (variante en el tiempo) y $w[n]$ es ruido blanco gaussiano de media cero. El receptor incorpora un ecualizador que compense, en la medida de lo posible, los efectos de la distorsión del canal. Como las características del canal son desconocidas y pueden cambiar con el tiempo, dicho ecualizador se implementa típicamente como un filtro adaptativo.

3.1.1. Criterio de Nyquist para ISI cero

La condición matemática de Nyquist para ISI cero es:

$$p(n \cdot T_s) = \begin{cases} 1, & n = 0 \\ 0, & n \neq 0 \end{cases}$$

donde T_s es el período de símbolo y $p(t)$ es la respuesta al pulso equivalente total. Es decir, el pulso debe tener cruces por cero en todos los múltiplos enteros del período de símbolo, excepto en $n = 0$.




Figura 22 - Diagrama del ojo

Nota. Tomado de *Digital Communications* (p. 603), por J. G. Proakis y M. Salehi, 2008, McGraw-Hill.

La condición equivalente en el dominio de la frecuencia es el criterio de Nyquist:

$$\sum_k P\left(f - \frac{k}{T_s}\right) = \text{constante}, \quad \forall f$$

donde $P(f)$ es la transformada de Fourier de $p(t)$. Una solución práctica de amplio uso es el coseno elevado (raised cosine), que cumplen el criterio con un parámetro de roll-off (factor de caída) $\alpha \in [0,1]$ que controla el compromiso entre ancho de banda y velocidad de caída temporal de los lóbulos laterales.




Figura 23 - Coseno elevado

Nota. Tomado de *Digital Communications* (p. 608), por J. G. Proakis y M. Salehi, 2008, McGraw-Hill.

Cuando el canal $h(n, k)$ se desvía del pulso Nyquist $p(t)$ diseñado, la condición se rompe y aparece ISI: el símbolo $x[k]$ recibido ya no contribuye únicamente a la muestra $y[k] = x[k] + \text{ruido}$, sino que contamina también a $y[k \pm 1]$, $y[k \pm 2]$, etc. Esto es exactamente lo que ocurre en este ejercicio: el canal FIR de 3 coeficientes $[\hat{h}_0, \hat{h}_1, \hat{h}_2]$ destruye el pulso Nyquist y, por tanto, requiere un ecualizador que reconstruya la condición.

En resumen, el ecualizador adaptativo de este problema es, en esencia, una estimación en línea del filtro inverso al canal que restaura el criterio de Nyquist de manera aproximada sobre la señal recibida.

Para este ejercicio, un mensaje de texto fue codificado en ASCII de 8 bits (MSB primero), convertido a una secuencia binaria y modulado con QPSK. El canal se modela de forma compacta como una FIR de 3 coeficientes variantes en el tiempo:

$$y[n] = h_0[n] x[n] + h_1[n] x[n-1] + h_2[n] x[n-2] + w[n]$$

El archivo ``data_comm.npz`` contiene:

- ``y``: la señal compleja recibida de longitud $N = 3744$ símbolos QPSK.
- ``entrenamiento``: los primeros 200 caracteres transmitidos, equivalentes a 800 símbolos QPSK, que se usan como secuencia de entrenamiento para inicializar el ecualizador. El resto del mensaje (2944 símbolos, 736 caracteres) es el contenido a recuperar.

3.2. Filtro de Wiener y ecualización adaptativa

El ecualizador adaptativo es una instancia particular del filtro de Wiener FIR estudiado en la Clase 12 de Milla Bravo (pp. 5-9). Sea $x[n]=y[n]$ la señal observada a la entrada del ecualizador y sea $d[n] = x_{\text{ref}}[n]$ la secuencia de símbolos QPSK de referencia. El filtro FIR causal de longitud L que minimiza $\xi = E\{|e[n]|^2\}$ satisface las ecuaciones de Wiener-Hopf (Milla Bravo, 2026, Clase 12, p. 9):

$$R_y \vec{w}_{\text{opt}} = \vec{r}_{dy} \quad \Rightarrow \quad \vec{w}_{\text{opt}} = R_y^{-1} \vec{r}_{dy}$$

donde R_y es la matriz de autocorrelación de $y[n]$ y $\vec{r}_{dy}$ es el vector de correlaciones cruzadas entre $d[n]$ y $y[n]$. El MSE mínimo alcanzable es

$$\xi_{\min} = r_d[0] - \vec{r}_{dy}^T R_y^{-1} \vec{r}_{dy}$$

a diferencia clave con el predictor lineal del Problema 2 es que aquí la señal de referencia $d[n]$ no es $y[n+1]$, sino una secuencia QPSK independiente (los bits transmitidos), por lo que las correlaciones $r_{dy}[k]$ no se reducen a un corrimiento de

$r_y[k]$. Esto hace que la solución de Wiener no pueda escribirse como una forma cerrada simple como $\vec{w}_{\text{opt}} = [a_1, a_2]^T$ en el caso AR(M). Aun así, la estructura es la misma en encontrar los coeficientes del FIR que minimizan el MSE, y luego usar el LMS para adaptarse a las variaciones lentas del canal.

3.3. Modulación QPSK

Es una modulación multisimbólica donde se agrupan cada 2 bits para generar 1 símbolo, además, el código de entrada es casi siempre polar. Se usa los dibit (IQ) el cual es la dupla de bits y cada par de bits (a_{2n}, a_{2n+1}) se mapea a un símbolo de la constelación $\{\pm 1 \pm j\}$ según

$$x[n] = (-1)^{a_{2n}} + j(-1)^{a_{2n+1}}$$

Como cada carácter ASCII tiene 8 bits y se transmiten 2 bits por símbolo QPSK, cada carácter produce 4 símbolos QPSK. A continuación, se ve su constelación y cómo se desplaza la señal enviada dependiendo de la dupla:




Figura 24 - Constelación QPSK

Nota. Tomado de *Modulación por desplazamiento de fase*, Wikipedia, https://es.wikipedia.org/wiki/Modulaci%C3%B3n_por_desplazamiento_de_fase




Figura 25 - Modulación QPSK

Nota. Tomado de *Understanding Quadrature Phase Shift Keying (QPSK) Modulation*, por Robert Keim, 2016, *All About Circuits*. <https://www.allaboutcircuits.com/technical-articles/quadrature-phase-shift-keying-qpsk-modulation/>

3.3.1. Probabilidad de error teórica de QPSK en AWGN

La constelación QPSK mostrada anteriormente tiene la propiedad de que todos sus puntos equidistan del origen y la distancia mínima entre símbolos adyacentes (asignados por código Gray) es $\sqrt{2} \cdot A$, donde A es la amplitud de cada coordenada I/Q.

Para un canal AWGN con densidad espectral de potencia de ruido $N_0/2$ por dimensión y energía promedio por bit $E_b = A^2 \cdot T_s$ (con T_s el período de símbolo), la probabilidad de error de bit teórica de QPSK con detección coherente es idéntica a la de BPSK:

$$P_b = Q\left(\sqrt{\frac{2E_b}{N_0}}\right)$$

donde $Q(x) = \frac{1}{2\pi} \int_x^\infty e^{-\frac{t^2}{2}} dt$ es la función Q de Gauss. Esta igualdad se debe a que QPSK puede descomponerse en dos canales BPSK ortogonales (I y Q), cada uno con la misma E_b/N_0 , por lo que la probabilidad de error de bit es la misma, aunque la probabilidad de error de símbolo sea mayor.

3.4. Algoritmo LMS (Widrow-Hoff)

El ecualizador se implementa como un filtro adaptativo lineal (FIR) con L coeficientes complejos. La salida del ecualizador se construye como una combinación lineal de muestras de la señal recibida:

$$\hat{x}[n] = w^H[n] y_L[n] = \sum_{k=0}^{L-1} w_k^*[n] y[n - D - k]$$

donde D es un retardo de decisión opcional, $w[n] = [w_0, w_1, \dots, w_{L-1}]^T$ es el vector de coeficientes y $y_L[n] = [y[n - D], y[n - D - 1], \dots, y[n - D - L + 1]]^T$ es el regresor. El superíndice H denota conjugada traspuesta.

En este problema, se eligió el LMS **estándar** (no normalizado) por dos razones:

1. La señal de entrada al ecualizador es la señal $y[n]$ recibida, cuya potencia está acotada (es suma de tres términos QPSK pesados por los h_i); por lo tanto $|y_L|^2$ no presenta variaciones dinámicas grandes y la normalización aporta poco.
2. La implementación del LMS estándar es más simple y permite un análisis más directo del compromiso velocidad/estabilidad. La alternativa sería el NLMS (Milla Bravo, 2026, Clase 13, pp. 21–23) que normaliza el paso por $|y_L|^2 + \varepsilon$

3.5. Modo Decision-Directed

Una vez finalizada la fase de entrenamiento supervisado, el ecualizador puede seguir actualizándose usando sus propias decisiones como referencia. Esto es indispensable cuando el canal es variante en el tiempo, ya que permite que el ecualizador siga los cambios lentos del canal. La actualización en DD es:

$$\hat{x}_{\text{dec}}[n] = \text{sgn}(\hat{x}[n])$$

$$e[n] = \hat{x}_{\text{dec}}[n] - \hat{x}[n]$$

$$w[n+1] = w[n] + \mu_{\text{dd}} e^*[n] y_L[n]$$

En general se usa $\mu_{\text{dd}} < \mu$ para evitar que errores de decisión se propaguen. Este es el análogo directo del modo no supervisado en identificación de sistemas. En lugar de usar una referencia externa $d[n]$ (que requeriría re-transmitir símbolos conocidos), se usa una salida cuantizada del propio ecualizador como referencia. La hipótesis es que la ISI residual después de la convergencia es pequeña, por lo que la decisión difícil es esencialmente la del símbolo correcto.

3.6. Ecualizador DFE (Decision Feedback Equalizer)

El DFE combina un filtro FIR sobre la señal recibida con un filtro FIR sobre las decisiones pasadas:

$$\hat{x}[n] = w_f^H[n] y_L[n] - w_b^H[n] \hat{x}_{\text{pasado}}[n]$$

donde $\hat{x}_{\text{pasado}}[n] = [\hat{x}[n-1], \hat{x}[n-2], \dots, \hat{x}[n-L_b]]^T$ son las decisiones pasadas. La ventaja teórica del DFE sobre el LMS lineal es que puede cancelar ISI (efecto de símbolos anteriores sobre el símbolo actual) sin amplificar el ruido, ya que la respuesta usa decisiones que idealmente están libres de ruido. Cuando el canal tiene ceros cerca del círculo unitario, un ecualizador FIR lineal directo necesita un número grande de coeficientes para cancelar la ISI de símbolos anteriores, y cada coeficiente extra amplifica el ruido. El DFE resuelve este compromiso usando las decisiones pasadas (libres de ruido) en lugar de muestras presentes.

3.7. Modelo del Sistema y Carga de Datos

Se trabaja con la modulación QPSK según la convención del enunciado: cada par de bits (a_{2n}, a_{2n+1}) se mapea a un símbolo de la constelación $\{\pm 1 \pm j\}$. Las funciones de conversión implementadas siguen exactamente esa convención

3.7.1. Datos cargados

Longitud de y: 3744 símbolos QPSK

Entrenamiento: 200 caracteres = 800 símbolos QPSK

Mensaje a recuperar: 2944 símbolos = 736 caracteres

Primeros 20 caracteres de entrenamiento: KCxc-Rz_snbJS/O ;7{[

Estadísticas de y (primeros 200 símbolos):

|y| media: 3.250, std: 1.293

Re(y) std: 2.511, Im(y) std: 2.381

3.7.2. Verificación de la codificación/decodificación

Implementamos las funciones que convierten texto a bits y luego a símbolos QPSK, siguiendo la convención del enunciado: MSB primero por carácter, mapeo QPSK $(-1)^{a_{2n}} + j(-1)^{a_{2n+1}}$. Dándonos los siguientes resultados:

Secuencia entrenamiento: 800 símbolos QPSK

Primeros 6 símbolos entrenamiento: [1.-1.j 1.+1.j -1.+1.j -1.-1.j 1.-1.j 1.+1.j]

Bits decodificados de los primeros 8 símbolos: [0, 1, 0, 0, 1, 0, 1, 1, 0, 1, 0, 0, 0, 0, 1, 1]

Primeros 2 caracteres decodificados: 'KC'

Primeros 2 caracteres reales: 'KC'

3.8. Constelación de la señal recibida

La señal $y[n]$ recibida, según el modelo $y[n] = h_0[n]x[n] + h_1[n]x[n-1] + h_2[n]x[n-2] + w[n]$, se ve severamente distorsionada por la ISI introducida por los coeficientes variantes en el tiempo del canal. La constelación deja de presentar los cuatro puntos discretos $\{\pm 1 \pm j\}$ característicos de QPSK.




Figura 26 - Constelación de $y[n]$

3.9. Estimación de los Coeficientes del Canal

Se estima inicialmente los coeficientes del canal a partir de los 200 caracteres de entrenamiento. Como el canal es variante en el tiempo, no se puede hacer una estimación global. En su lugar, se utiliza el algoritmo LMS para seguir los valores instantáneos de los coeficientes:

$$\hat{y}[n] = \hat{h}_0[n] x[n] + \hat{h}_1[n] x[n-1] + \hat{h}_2[n] x[n-2]$$

$$e[n] = y[n] - \hat{y}[n]$$

$$\hat{h}[n+1] = \hat{h}[n] + \mu_h e^*[n] x[n]$$

donde $x[n] = [x[n], x[n-1], x[n-2]]^T$ y $\hat{h}[n] = [\hat{h}_0, \hat{h}_1, \hat{h}_2]^T$. El LMS estima simultáneamente la respuesta impulsiva actual del canal y sigue su evolución temporal.

Los resultados de la estimación con $\mu_h = 0.01$ sobre los 800 símbolos de entrenamiento son:

Coeficientes estimados al final del entrenamiento:

$$\hat{h}_0 = +1.9530 - 0.0252j \quad |\hat{h}_0| = 1.9532$$

$$\hat{h}_1 = -0.1335 - 0.0118j \quad |\hat{h}_1| = 0.1340$$

$$\hat{h}_2 = +0.1311 + 0.0137j \quad |\hat{h}_2| = 0.1318$$

Promedio sobre el entrenamiento (n=50..800):

$$\hat{h}_0 \text{ medio} = +1.9405 - 0.0035j \pm 0.1323$$

$$\hat{h}_1 \text{ medio} = -0.6407 - 0.0028j \pm 0.2688$$

$$\hat{h}_2 \text{ medio} = +0.6165 + 0.0032j \pm 0.2629$$

SE final del estimador: 0.5078

Análisis

La magnitud del coeficiente principal $\hat{h}_0$ se mantiene aproximadamente constante en $|\hat{h}_0| \approx 1.95$ a lo largo del entrenamiento, lo que indica que el canal tiene una ganancia aproximadamente estable. Sin embargo, $\hat{h}_1$ y $\hat{h}_2$ tienen una variabilidad mucho mayor, lo que evidencia la naturaleza variante en el tiempo del canal. El SE final del estimador (aproximadamente 0.5) no es cero precisamente porque el canal es variante: el LMS persigue un objetivo móvil y no puede eliminar completamente el error de modelado. Esta es la misma conclusión que se obtendría en un predictor lineal sobre un AR con coeficientes variantes: el MSE de estado estacionario está acotado inferiormente por la velocidad de variación del proceso.

3.10. Evolución temporal de los coeficientes del canal

La siguiente figura muestra cómo varían los coeficientes h_0, h_1, h_2 a lo largo del entrenamiento. Se observa que h_0 se mantiene aproximadamente constante (aproximadamente 1.95), mientras que h_1 y h_2 varían significativamente (lo que confirma la naturaleza variante en el tiempo del canal y es la causa principal de la ISI).




Figura 27 - Coeficientes del canal estimados por LMS en el entrenamiento

3.11. Zero-Forcing con canal estimado

Conociendo la estimación del canal $\hat{h}$, una primera idea es construir un ecualizador zero-forcing (ZF): el inverso exacto del canal. Para un canal de 3 coeficientes $\hat{h}$, la cancelación de la ISI anterior equivale a un DFE con dos coeficientes de retroalimentación:

$$\hat{x}[n] = \frac{1}{\hat{h}_0} y[n] - \frac{\hat{h}_1}{\hat{h}_0} \hat{x}[n-1] - \frac{\hat{h}_2}{\hat{h}_0} \hat{x}[n-2]$$

Sin embargo, como el canal es variante en el tiempo, usar un $\hat{h}$ fijo (p.ej. el promedio) no es óptimo. La mejor opción es el ecualizador LMS adaptativo, que sigue los cambios del canal en tiempo real. Aún así, mostramos el ZF para ilustrar el efecto de la estimación del canal.

Aplicando el Zero-Forcing con un promedio del entrenamiento sobre toda la señal nos da que la tasa de bit de error es de 0.5363.

Primeros 200 caracteres con Zero-Forcing: 6720'¥÷6æ\$¥2ôö—
 3w•ÇB0ecuxs"µu45âÄÄtRö4gæcâ7âô&JU3çó2Ö'\$6eÇÇâæµfECwDÓVÔÄöÄDÄòµ²V!
 gDÄ\$ò\$tUC3ärGÄceÖâÄÄV%2÷6¶r3—µ¥µu'ÉÄ•µccf³
 "xTtBR3f4gµâGçwÓµ\$U"âÄ
 %µ#v3cd\$&öt

Caracteres 200-400: ÆWG&FR%6R
 ÆÆÖW/¢ ¤6÷6V6æFðÖ2Ö&W¥6VÖ' &æFðÖ2F2W\$&0¥ðVW&ðP2ÖG&¤Öæ6âVRÇV6æ
 FÖ¥&ö×2Æ26FVæ0¤FRÆW66ÆfGV@¤W2ÆF¤W' &FVÂ
 æ6¥VRVÂ6öÂÆÇVÖæ¥

¢FRÆVæ6à¥ðÖRÆÖðW/ ¥VW2Ö&|W' Væ¤6öâÆ6æw&R¤VÂÆÖ¥ç02Æ÷26öÆ÷&W2FRÖ¤&VÆİ6à
 ¤6ö×÷6¤F÷#¢
 VwW7FðöÆð
 6×÷0

Tiene "Compositor": False

Por lo que el ZF no recupera el mensaje: el texto decodificado es incomprensible. El BER de aproximadamente 54% confirma que un $\hat{h}$ fijo (promedio) no es suficiente para compensar las variaciones temporales del canal. Esto valida empíricamente que la estimación exacta del canal es difícil en canales variantes en el tiempo, y que el LMS adaptativo es preferible. La razón teórica es que el ecualizador de Wiener $R_y^{-1}\vec{r}_{dy}$ usa R_y que cambia con el tiempo; un $\hat{h}$ fijo produce un ecualizador equivalente al de Wiener solo en el instante $n = n_0$ donde se hizo la estimación, y se desactualiza rápidamente.

3.12. Ecualizador LMS Lineal

Habiendo estimado el canal en la sección anterior, procedemos a diseñar el ecualizador. Implementamos el ecualizador LMS con dos fases:

1. Entrenamiento supervisado sobre los primeros 800 símbolos.
2. Modo decision-directed sobre los 2944 símbolos restantes, usando las decisiones del propio ecualizador.

3.12.1. Selección de parámetros

Para el ecualizador LMS lineal elegimos los siguientes parámetros:

Parámetro	Valor	Justificación
L (coeficientes)	11	Suficiente para cancelar la ISI de 3 coeficientes con margen para adaptación; L muy grande (≥ 21) sobreajusta al ruido de entrenamiento
D (retardo)	0	Con QPSK y canal dispersivo de 3 coeficientes, el ecualizador óptimo se centra en $D=0$
μ (entrenamiento)	0.007	Compromiso entre velocidad de convergencia y estabilidad numérica;

		menor que $1/\text{tr}(\mathbf{R}_y)$ con $\text{tr}(\mathbf{R}_y) = Lr_y[0] \approx 11 \cdot 4 \approx 44$, o sea $\mu \ll 1/44 \approx 0.023$
μ_{dd} (decision-directed)	0.001	Menor que μ para evitar propagación de errores de decisión

La elección de L se hizo experimentalmente. Con L pequeño (3-5), el ecualizador no cancela completamente la ISI; con L muy grande (21-31), se sobreajusta y degrada la generalización. La cota práctica da $\mu < 1/\text{tr}(\mathbf{R}_y) \approx 1/(L \cdot E\{|y[n]|^2\})$, lo que con $E\{|y[n]|^2\} \approx 4$ para los primeros 200 símbolos da $\mu < 0.023$, compatible con $\mu = 0.007$ elegido.

3.12.2. Resultados del entrenamiento

L = 11, D = 0, $\mu_{\text{train}} = 0.007$, $\mu_{dd} = 0.001$

Período de entrenamiento: 800 símbolos

Período decision-directed: 2944 símbolos

Coefficientes del ecualizador (L=11):

$w[0] = +0.4570 - 0.0020j$ $|w[0]| = 0.4570$
 $w[1] = +0.1535 - 0.0034j$ $|w[1]| = 0.1535$
 $w[2] = -0.0959 + 0.0025j$ $|w[2]| = 0.0959$
 $w[3] = -0.0689 + 0.0073j$ $|w[3]| = 0.0693$
 $w[4] = +0.0172 + 0.0030j$ $|w[4]| = 0.0175$
 $w[5] = +0.0240 + 0.0015j$ $|w[5]| = 0.0241$
 $w[6] = -0.0056 + 0.0055j$ $|w[6]| = 0.0078$
 $w[7] = -0.0128 + 0.0017j$ $|w[7]| = 0.0130$
 $w[8] = +0.0042 - 0.0023j$ $|w[8]| = 0.0048$
 $w[9] = +0.0110 - 0.0065j$ $|w[9]| = 0.0128$
 $w[10] = -0.0008 + 0.0006j$ $|w[10]| = 0.0009$

BER total en el entrenamiento: 0.0081 (13 errores / 1600 bits)

Los coeficientes del ecualizador muestran un decaimiento exponencial a partir de $w[0]$, consistente con la respuesta impulsiva de un ecualizador inverso al canal: el lóbulo principal concentra casi toda la energía ($|w[0]| = 0.457$) y los coeficientes lejanos tienden a cero ($|w[k]| < 0.03$ para $k \geq 5$). El BER de entrenamiento es aproximadamente 0.8%, lo que indica que el ecualizador converge robustamente durante los primeros 800 símbolos.

3.13. Análisis de Convergencia

Graficamos la curva del error cuadrático instantáneo $|e[n]|^2$ a lo largo del proceso de adaptación, junto con el BER móvil. Durante la fase de entrenamiento el error decrece

conforme los coeficientes convergen; durante la fase DD el ecualizador sigue las variaciones del canal.




Figura 28 - Convergencia del ecualizador LMS lineal

Se observa que:

- El error cae rápidamente durante los primeros 4 bloques (aproximadamente 160 símbolos) hasta un valor cercano a la mitad de la inicial, y continúa decreciendo hasta un piso de ruido en torno a -10 dB.
- El BER móvil se acerca a 0% en los bloques 2-3 del entrenamiento, confirmando que el ecualizador alcanza la convergencia.

El ecualizador converge rápidamente: en aproximadamente 160 símbolos (de los 800 disponibles para entrenamiento) el error cuadrático cae a la mitad de su valor inicial. Esto es coherente con la teoría del LMS (Milla Bravo, 2026, Clase 13, pp. 19–20): la velocidad de convergencia está dominada por el modo lento asociado al autovalor más chico de R_y , y el tiempo característico escala como $1/\mu\lambda_{\min}R_y$

3.14. Constelación Post-Ecualización

Aplicamos el ecualizador entrenado a toda la señal recibida. La constelación post-ecualización muestra claramente los cuatro puntos de la constelación QPSK $\{1 + j, 1 - j, -1 + j, -1 - j\}$, confirmando la cancelación efectiva de la ISI.




Figura 29 - Constelación antes y después de ecualizar

3.15. Recuperación del Mensaje

Decodificamos los bits decididos por el ecualizador a lo largo de toda la secuencia. Los primeros 200 caracteres decodificados deben coincidir (salvo errores residuales) con el entrenamiento original, y el resto del mensaje corresponde al texto desconocido a recuperar.

Caracteres decodificados: 936

Primeros 200 caracteres (entrenamiento):

ëKIc-bk_snbJS/O ;7{[v 1]FV1pW]w9r+WS@ S^,L,GE/PSF~f8n#• -AIArkeS:/0S-
RrCfY)|~.hZFj47y4M5m\PIX\$LM+[%ajhQ&tL"O"GET39NG!T|F6]n\iL%hbS
_skaW#1`9ZX'Y+J<[x&61*8Q({1r-}uIgD%#6cFx{^\$~w};Y9rER(N,@BY1R7c66AZr
oW

Caracteres 200 a 400 (transición entrenamiento a mensaje):

Letra de "Y Se Llama Perú"

Cosechando mis mares
Sembrando mis tierras
Yo quiero más a mi patria
Mi nación que luchando
Rompió las cadenas
De la esclavitud
Es la tierra del Inca
Que el sol la ilumina

Últimos 200 caracteres del mensaje:

Perú
 Con P de patria
 La E del ejemplo
 La R del rifle
 La Ú de la unión
 Yo me llamo Perú
 Pues mi raza peruana
 Con la sangre y el alma
 Pintó los colores de mi pabellón

Compositor: Augusto Polo Campos

Coincidencias con entrenamiento: $192/200 = 96.0\%$

El mensaje recuperado corresponde a la letra de la canción "Y Se Llama Perú" de Augusto Polo Campos (autor peruano de vales criollos). Las pequeñas diferencias en los primeros 200 caracteres respecto al entrenamiento real ($192/200 = 96\%$ de coincidencia exacta) corresponden a errores residuales del ecualizador durante la fase inicial de convergencia; el resto del mensaje, ya en la etapa DD, se decodifica sin errores. Esto valida que el modo DD funciona correctamente: el ecualizador mantiene BER aproximadamente 0 durante 2944 símbolos sin necesidad de referencia externa.

3.16. Ecualizador DFE

Para la comparación, entrenamos un DFE inicializado desde el LMS lineal ya entrenado. La esperanza es mantener (o mejorar) el rendimiento del LMS lineal, especialmente en la fase DD donde la retroalimentación sobre las decisiones pasadas puede cancelar ISI anterior más efectivamente.

Parámetro	Valor
L_f (coeficientes de anticipación)	11
L_b (coeficientes de retroalimentación)	3
D (retardo)	0
μ (entrenamiento)	0.005
μ_{dd} (decision-directed)	0.001

El DFE alcanza BER aproximadamente 0 durante la fase de entrenamiento, igualando (sin superar) al LMS lineal. Esto sugiere que la inicialización desde el LMS lineal es suficiente y que el canal no presenta ISI anterior severa que justifique la complejidad adicional de la retroalimentación.

3.17. Comparación LMS Lineal vs DFE

Comparamos ambos ecualizadores en términos de error cuadrático instantáneo y BER durante la fase de entrenamiento y DD:




Figura 30 - Comparación LMS Lineal vs DFE

Se observa que:

- Durante el entrenamiento, las dos arquitecturas tienen SE muy similar después de la convergencia (aproximadamente -20 dB).
- El DFE tiene un ligero offset de BER en los primeros bloques (porque solo produce decisiones a partir del símbolo $n = L_f = 11$), pero en régimen estacionario ambos convergen a BER aproximadamente 0.
- En la fase DD, las dos curvas son prácticamente indistinguibles, confirmando que la inicialización desde el LMS lineal transfiere correctamente el conocimiento al DFE.

Arquitectura	BER total	BER últimos 100
Zero-Forcing ($\hat{h}$ estimado)	0.5363	-
LMS Lineal ($L=11$)	0.0081	0.0000
DFE ($L_f=11, L_b=3$)	0.0000	0.0000

El LMS lineal con DD recupera el mensaje completo correctamente, y el DFE no aporta una mejora significativa en este caso porque el canal solo tiene 3 coeficientes.

3.18. Conclusiones

Del estudio de ecualización adaptativa de canal se concluye que:

1. El LMS lineal con decision-directed recupera correctamente el mensaje. El texto decodificado corresponde a la letra de la canción "Y Se Llama Perú" de Augusto Polo Campos. Las pequeñas diferencias en los primeros 200 caracteres (96% de coincidencia exacta) corresponden a errores residuales durante la convergencia inicial; el resto del mensaje se decodifica sin errores.

2. El ecualizador es una instancia del filtro de Wiener FIR adaptativo. La estructura matemática es idéntica a la del predictor lineal del Problema 2, con la diferencia de que aquí la señal de referencia $d[n] = x_{\text{ref}}[n]$ es una secuencia QPSK independiente (no un corrimiento de $y[n]$). Esto implica que la solución de Wiener $R_y^{-1} \vec{r}_{dy}$ no se reduce a una forma cerrada simple, pero el LMS la aproxima muestra a muestra con un costo $O(L)$ por iteración (Milla Bravo, 2026, Clase 13, p. 13).

3. El modo decision-directed es indispensable para canales variantes en el tiempo: la mayor parte del mensaje (2944 de 3744 símbolos) se recupera en este modo. Sin DD, el ecualizador entrenado en los primeros 800 símbolos diverge al aplicarlo a los siguientes 2944 (el canal cambia y los coeficientes quedan obsoletos). Con DD, el ecualizador sigue al canal y mantiene BER bajo a lo largo de toda la transmisión.

4. El Zero-Forcing con canal estimado promedio es insuficiente. Aunque el LMS estima correctamente la tendencia de los coeficientes del canal, usar un $\hat{h}$ fijo (promedio) en un ZF da BER aproximadamente 54%. El LMS adaptativo es claramente superior porque sigue al canal en tiempo real. La razón teórica es que la solución de Wiener depende de R_y que es variante: un $\hat{h}$ fijo solo es válido en el instante de la estimación.

5. El DFE no aporta mejora significativa en este problema. Teóricamente el DFE debería superar al LMS lineal en canales con ISI anterior severa, pero las razones por las que no lo hace aquí son:

- El canal tiene solo 3 coeficientes, lo que no genera ISI anterior severa que justifique la complejidad adicional del DFE.
- El LMS lineal con DD ya es capaz de seguir las variaciones del canal, anulando la ventaja teórica del DFE.
- La inicialización desde el LMS lineal entrenado (que ya tiene BER aproximadamente de 0 en el entrenamiento) hace que el DFE no tenga margen de mejora y pueda incluso degradar la solución por sobreajuste.

6. Existe un compromiso fundamental velocidad/estabilidad en el LMS: μ grande acelera la convergencia, pero aumenta la varianza estacionaria y el riesgo de divergencia; μ pequeño da convergencia más lenta pero más estable. En DD se usa μ aún menor para evitar la propagación de errores de decisión. En la práctica se respeta la cota $\mu < 1/\text{tr}(R_y) = 1/(Lr_y[0])$ (Milla Bravo, 2026, Clase 13, p. 20), que con $L = 11$ y $r_y[0] \approx 4$ da $\mu \lesssim 0.023$, compatible con $\mu = 0.007$ elegido.

7. La selección de L es empírica pero crítica. Con L pequeño (3-5), el ecualizador no cancela completamente la ISI. Con L grande (21-31), se sobreajusta al ruido de entrenamiento y degrada la generalización. $L = 11$ ofrece el mejor balance para este caso con canal de 3 coeficientes.

Referencias bibliográficas

- Keim, R. (2016, 17 de agosto). *Understanding quadrature phase shift keying (QPSK) modulation*. All About Circuits.
<https://www.allaboutcircuits.com/technical-articles/quadrature-phase-shift-keying-qpsk-modulation/>
- Manolakis, D. G., & Ingle, V. K. (2011). *Applied Digital Signal Processing: Theory and Practice*. Cambridge University Press.
- Milla, M. (2026). *IEE352 - Procesamiento Digital de Señales, Clases 12-13* [Materiales de clase]. PUCP.
- Modulación por desplazamiento de fase. *Wikipedia*.
https://es.wikipedia.org/wiki/Modulaci%C3%B3n_por_desplazamiento_de_fase
- Oppenheim, A. V., & Schafer, R. W. (2010). *Discrete-Time Signal Processing*. (3rd ed.). Pearson.
- Proakis, J. G., & Salehi, M. (2008). *Digital Communications* (5th ed.). McGraw-Hill.

